

**UNIVERSIDADE FEDERAL DE MINAS GERAIS**  
**INSTITUTO DE CIÊNCIAS EXATAS**  
**DEPARTAMENTO DE ESTATÍSTICA**

ELIANA CARDOSO GONÇALVES

**MODELAGEM DA VARIÁVEL ORDINAL COM EFEITO ALEATÓRIO:**

Comparação entre as abordagens de regressão linear e regressão logística ordinal em um estudo de caso.

BELO HORIZONTE

2025

ELIANA CARDOSO GONÇALVES

**MODELAGEM DA VARIÁVEL ORDINAL COM EFEITO ALEATÓRIO:**

Comparação entre as abordagens de regressão linear e regressão logística ordinal em um estudo de caso.

Monografia apresentada ao Departamento de Estatística da Universidade Federal de Minas Gerais como parte das exigências para obtenção do título de Bacharel em Estatística

---

Dr. Ilka Afonso Reis  
Orientadora

---

Dr. Sarah Prates  
Co-orientadora

BELO HORIZONTE

2025

Dedico esta monografia à curiosidade e à busca por compreender o mundo, mesmo sabendo que, como disse o estatístico britânico George Box, “todos os modelos estão errados, mas alguns são úteis”. Que este estudo represente uma tentativa sincera de encontrar utilidade na complexidade dos dados e contribuir, ainda que modestamente, para o conhecimento científico.

## AGRADECIMENTO

Agradeço primeiramente a Deus, pela saúde, força e fé que me sustentaram durante toda esta caminhada.

Aos meus pais, Nadil e Luiza, por todo amor, apoio incondicional e por sempre me apoiarem. Às minhas irmãs, por serem minhas melhores amigas.

Aos meus amigos e colegas, pelas conversas, risadas e por me lembrarem de que eu não estava sozinha nesse percurso. Àqueles que torceram por mim, mesmo de longe, o meu carinho e gratidão.

À minha orientadora, Professora Ilka Afonso Reis, pela paciência em me ensinar. Sua orientação foi essencial para a realização deste trabalho.

Agradeço também aos professores e funcionários do Departamento de Estatística da UFMG, pela formação sólida, pelo ambiente de aprendizado e acolhimento — e à FUMP, que me deu coragem para me mudar para BH com o suporte financeiro que tornou tudo possível.

Por fim, agradeço a mim mesma — por não desistir. Cada desafio superado neste percurso contribuiu não apenas para esta monografia, mas para a pessoa que me tornei.

Muito obrigada!

## RESUMO

Esta monografia tem como objetivo avaliar os impactos da escolha metodológica entre a regressão linear mista e a regressão logística ordinal com efeitos aleatórios na modelagem de variáveis ordinais obtidas por escalas de Likert. Para isso, foi reaplicado o modelo de regressão linear utilizado por Prates et al. (2022) e realizada uma reanálise com a regressão logística ordinal mista, utilizando o mesmo banco de dados. O estudo original investigava o efeito de diferentes modelos de Rotulagem Nutricional Frontal (RNF) — octógono, triângulo e lupa — na percepção de saudabilidade de alimentos supostamente saudáveis por consumidores brasileiros.

Os resultados mostraram que a regressão logística ordinal mista é mais adequada para variáveis com estrutura ordinal, especialmente em contextos com hierarquia nos dados e quando se trata de escalas de Likert. Esse modelo respeita a natureza dos dados e permite a interpretação direta por meio das odds ratios, que não dependem do tamanho da escala. Além disso, foi capaz de capturar efeitos principais e interações que o modelo linear não identificou.

Em termos substantivos, observou-se que todos os modelos de RNF aumentaram a percepção de que os produtos eram pouco saudáveis, sobretudo quando apresentavam nutrientes críticos em excesso e ausência de alegações. Entre os rótulos, o octógono e o triângulo se destacaram como os mais eficazes, em comparação ao modelo da lupa — atualmente adotado no Brasil.

Conclui-se que o modelo ordinal misto oferece uma alternativa metodológica mais robusta para dados provenientes de escalas de classificação, ao mesmo tempo em que os resultados do estudo reforçam a eficácia das estratégias de rotulagem frontal como instrumento de apoio à promoção da saúde pública.

**Palavras-chave:** Variável ordinal, Escala de Likert, Regressão Ordinal, Regressão Linear, Efeito Aleatório.

## LISTA DE FIGURAS

1	Modelos de rotulagem nutricional frontal testados no estudo e alocação dos participantes e alocação dos participantes nas condições de intervenção do estudo	16
2	Combinação de fatores considerados para o desenvolvimento do rótulo: categoria de alimento (barra de cereal, snack e biscoito); tipo de produto (contendo 1 ou 2 nutrientes em excesso); alegação nutricional (presente vs. ausente). . . . .	17
3	Análise de resíduos do Glm - Normalidade e Homoscedasticidade . . . . .	30

## LISTA DE TABELAS

1	Resultado da Análise de Variância (ANOVA) para Saudabilidade . . . . .	21
2	Pontuações médias de saudabilidade por categoria de Alimento . . . . .	22
3	Resultados das Comparações Pós-Hoc entre Categoria de alimento . . . . .	22
4	Pontuações médias saudabilidade por Grupo RNF X Nutrientes em excesso X Alegações nutricionais . . . . .	22
5	Resultados das Comparações Pós-Hoc das interações Grupo RNF X Quantidade de nutrientes em excesso X Alegação . . . . .	23
6	Resultado da Regressão logística Ordinal para Saudabilidade . . . . .	25
7	Resultados das comparações entre Grupos RNF, considerando a presença ou ausência de alegação nutricional e a quantidade de nutrientes em excesso (1 ou 2) em produtos da categoria Snack . . . . .	26
8	Resultados das comparações entre grupos RNF, considerando a presença ou ausência de alegação nutricional e a quantidade de nutrientes em excesso (1 ou 2) em produtos da categoria Biscoito . . . . .	27
9	Resultados das comparações entre grupos RNF, considerando a presença ou ausência de alegação nutricional e a quantidade de nutrientes em excesso (1 ou 2) em produtos da categoria Barra de cereal . . . . .	28
10	Informações sobre os principais modelos de regressão logística ordinal, indicação de uso e pacotes R . . . . .	32

## SUMÁRIO

<b>1</b>	<b>INTRODUÇÃO</b>	<b>1</b>
<b>2</b>	<b>FUNDAMENTAÇÃO TEÓRICA</b>	<b>3</b>
2.1	Modelo Regressão Linear Misto . . . . .	3
2.1.1	Estrutura Geral de um Modelo Linear Misto (MLM) . . . . .	4
2.1.2	Modelos Relacionados e Extensões: . . . . .	5
2.1.3	Pressupostos da Regressão linear mista . . . . .	7
2.2	Modelo de Regressão Logística Ordinal . . . . .	9
2.2.1	Interpretação dos Coeficientes $\beta$ . . . . .	11
2.2.2	Interpretação da Odds Ratio no Modelo de Odds Proporcionais (MOP) . . . . .	12
2.2.3	Suposição de Odds Proporcionais . . . . .	13
2.2.4	Modelos Alternativos à OLR com MOP . . . . .	15
<b>3</b>	<b>METODOLOGIA</b>	<b>16</b>
3.1	Participantes e Desenho Experimental . . . . .	16
3.2	Procedimento experimental . . . . .	18
3.3	Análise dos dados . . . . .	18
<b>4</b>	<b>RESULTADOS</b>	<b>21</b>
4.1	Regressão Linear Mista . . . . .	21
4.2	Regressão Logística Ordinal Mista . . . . .	25
<b>5</b>	<b>DISCUSSÃO</b>	<b>29</b>
5.1	Regressão Linear Mista . . . . .	29
5.2	Regressão Logística Ordinal Mista . . . . .	31
<b>6</b>	<b>CONCLUSÃO</b>	<b>34</b>
<b>7</b>	<b>REFERÊNCIA</b>	<b>36</b>



## 1. INTRODUÇÃO

Em diversas áreas da pesquisa, especialmente nas ciências sociais e humanas, é comum a coleta de dados por meio de variáveis ordinais, nas quais as categorias possuem uma ordem inerente, mas a distância entre elas não é necessariamente uniforme (Eiselen et al., 2023; Costa Júnior et al., 2024; Kleinbaum et al., 2010). Um exemplo proeminente dessa natureza de dado é a obtida através da escala de Likert, amplamente utilizada para medir atitudes, opiniões e percepções, na qual os respondentes indicam seu nível de concordância ou discordância em uma escala com categorias ordenadas (Eiselen et al., 2023; Costa Júnior et al., 2024; Liddell et al., 2018). A modelagem adequada dessas variáveis ordinais é crucial para obter inferências válidas e evitar interpretações equivocadas dos resultados da pesquisa (Abreu et al., 2009; Liddell et al., 2018). Ignorar a natureza ordinal dos dados e aplicar métodos estatísticos desenvolvidos para dados intervalares ou de razão pode levar a conclusões falaciosas (Eiselen et al., 2023; Liddell et al., 2018).

Uma prática comum, porém controversa, é tratar os dados da escala de Likert como se fossem dados intervalares, permitindo a utilização de técnicas estatísticas paramétricas como a **regressão linear** e a **análise de variância (ANOVA)**. Essa abordagem facilita a aplicação de métodos estatísticos mais familiares e a obtenção de medidas como médias e desvios padrão. No entanto, essa prática desconsidera a natureza ordinal dos dados, levantando questionamentos sobre a validade dos pressupostos estatísticos subjacentes e a interpretabilidade dos resultados (Eiselen et al., 2023; Liddell et al., 2018; Costa Júnior et al., 2024).

Em contrapartida, existem modelos de regressão especificamente desenvolvidos para variáveis ordinais, como a regressão logística ordinal (OLR) e seus diferentes tipos (odds proporcionais, odds proporcionais parciais, razão contínua, estereótipo), que respeitam a ordenação das categorias da variável resposta (Eiselen et al., 2023; Abreu et al., 2009; Kleinbaum et al., 2010). Além disso, quando os dados possuem estrutura hierárquica — como respostas agrupadas por indivíduos, instituições ou localidades —, é fundamental considerar efeitos aleatórios para captar a variabilidade entre os grupos e evitar a violação da independência entre observações (Gelman & Hill, 2007; Raudenbush & Bryk, 2002). A incorporação de modelos mistos, que combinam efeitos fixos e aleatórios, permite uma modelagem mais realista e robusta nesses contextos, especialmente em pesquisas com dados provenientes de múltiplas unidades amostrais (Snijders & Bosker, 2012; Hox et al., 2017).

A comparação entre os resultados obtidos por meio da regressão linear, tratando os dados ordinais como intervalares, e da regressão ordinal com efeitos aleatórios é, portanto, fundamental para avaliar as potenciais diferenças nas conclusões e a adequação de cada abordagem. Assim, o objetivo deste estudo foi analisar como a escolha entre a regressão linear e a regressão logística ordinal com efeitos aleatórios impacta a modelagem de variáveis oriundas de escalas de Likert, considerando as implicações dessa decisão na interpretação dos

dados e nas conclusões da pesquisa. Como o objetivos específicos, pode-se citar:

- Comparar a adequação do ajuste dos modelos gerados pela regressão linear e pela regressão logística ordinal, utilizando os mesmos dados ordinais;
- Analisar as diferenças na interpretação dos coeficientes e das medidas de efeito, como *odds ratios* e média, produzidas pela regressão logístca ordinal e pela regressão linear, respectivamente;
- Avaliar a robustez de cada método frente às características específicas dos dados ordinais, como a desigualdade das distâncias entre as categorias;
- Investigar a potencial ocorrência de erros de interpretação (falsos positivos ou negativos, inversão de efeitos) ao tratar dados ordinais como intervalares na regressão linear.

Ao abordar esses pontos, este estudo visa fornecer uma compreensão mais aprofundada das implicações da escolha entre regressão linear e regressão ordinal na análise de variáveis ordinais, contribuindo para uma prática estatística mais informada e rigorosa em pesquisas que utilizam escalas como a de Likert.

## 2. FUNDAMENTAÇÃO TEÓRICA

### 2.1. Modelo Regressão Linear Misto

Os Modelos Lineares Mistos (MLMs) constituem uma abordagem estatística poderosa para lidar com dados que apresentam estrutura hierárquica ou agrupada (Freitas Souza et al., 2024; Bauer & Sterba, 2011). Embora sejam conhecidos por diferentes nomes — como modelos hierárquicos (Bauer & Sterba, 2011; Hedeker & Gibbons, 2006), modelos de efeitos aleatórios (Bauer & Sterba, 2011; Hedeker & Gibbons, 2006), modelos de coeficientes aleatórios (Bauer & Sterba, 2011; Hedeker & Gibbons, 2006; Skrondal & Rabe-Hesketh, 2004), modelos mistos (Kleinbaum & Klein, 2010; Hedeker & Gibbons, 2006) ou dados longitudinais ou agrupados, também são chamados de modelos multinível ou modelos de componentes de variância (Freitas Souza et al., 2024), todos esses termos referem-se a uma mesma concepção fundamental (Hedeker & Gibbons, 2006).

A principal característica dos modelos lineares mistos é a inclusão de **efeitos aleatórios** na estrutura do modelo de regressão (Kleinbaum & Klein, 2010; Hedeker & Gibbons, 2006). Esses efeitos aleatórios — como aqueles específicos de sujeitos, grupos ou clusters — são essenciais para capturar a variabilidade entre unidades e modelar a dependência entre observações repetidas ou agrupadas (Hedeker & Gibbons, 2006). Ao considerar essa variação, os modelos mistos superam a suposição de independência entre observações, comumente exigida por abordagens estatísticas tradicionais (Hedeker & Gibbons, 2006; Bauer & Sterba, 2011). Em contextos longitudinais, por exemplo, os efeitos aleatórios permitem modelar as trajetórias individuais ao longo do tempo, refletindo padrões específicos de cada sujeito e a estrutura de correlação entre as medidas (Hedeker & Gibbons, 2006).

Os modelos lineares mistos são extensões naturais do modelo linear clássico (Lavielle & Bleakley, 2015; Rencher & Schaalje, 2008; Freitas Souza et al., 2024), sendo especialmente indicados para a análise de dados com estrutura hierárquica (Freitas Souza et al., 2024), como indivíduos aninhados em grupos, ou medidas repetidas ao longo do tempo (Kleinbaum & Klein, 2010; Freitas Souza et al., 2024; Hedeker & Gibbons, 2006). Eles possibilitam a modelagem de tendências (lineares, curvilíneas ou polinomiais), tanto em nível populacional quanto individual (Hedeker & Gibbons, 2006; Kleinbaum & Klein, 2010). Em comparação com métodos tradicionais, como ANOVA e MANOVA para medidas repetidas, os MLMs oferecem vantagens substanciais: permitem lidar com dados incompletos, acolhem diferentes números de observações por unidade e não exigem estruturas de covariância simplificadas (Hedeker & Gibbons, 2006; Liu & Agresti, 2005).

Além disso, os modelos mistos também acomodam estruturas mais complexas, como efeitos aleatórios **cross-classificados** (Skrondal & Rabe-Hesketh, 2004), em que unidades estão simultaneamente agrupadas em diferentes níveis (Skrondal & Rabe-Hesketh, 2004), como indivíduos avaliados em diferentes momentos ou pertencentes a múltiplos contextos

(Skrondal & Rabe-Hesketh, 2004). Essa flexibilidade torna os modelos lineares mistos uma ferramenta essencial para a análise de dados reais, frequentemente desbalanceados e interdependentes (RUBIN, 2006; Liu & Agresti, 2005; Bauer & Curran, 2011; Kleinbaum & Klein, 2002 )

### 2.1.1. Estrutura Geral de um Modelo Linear Misto (MLM)

A estrutura geral de um Modelo Linear Misto pode ser expressa pela seguinte equação matricial:

$$\mathbf{y} = \mathbf{X}\beta + \mathbf{Z}\eta + \varepsilon$$

Onde:

- $\mathbf{X}\beta$  representa os **efeitos fixos**, onde  $\mathbf{X}$  é a matriz das variáveis explicativas (covariáveis) e  $\beta$  é o vetor de coeficientes associados. Esses efeitos descrevem tendências gerais ou médias populacionais, assumidas como constantes para todas as unidades da amostra (Montgomery, 2017; Skrondal; Rabe-Hesketh, 2004; Freitas Souza et al., 2004)
- $\mathbf{Z}\eta$  representa os **efeitos aleatórios** (Skrondal & Rabe-Hesketh, 2004), com  $\mathbf{Z}$  sendo a matriz que associa as observações aos efeitos aleatórios e  $\eta$  o vetor desses efeitos (Skrondal & Rabe-Hesketh, 2004; Rubin, 2006; Rencher; Schaalje, 2008). Os efeitos aleatórios capturam a variabilidade entre unidades (como indivíduos, grupos ou clusters) em torno da média representada pelos efeitos fixos (Skrondal & Rabe-Hesketh, 2004; Rubin, 2006; Kleinbaum & Klein, 2002; Rencher; Schaalje, 2008) . Em geral, assume-se que os efeitos aleatórios possuem média zero e uma matriz de covariância específica (Rencher; Schaalje, 2008; Skrondal; Rabe-Hesketh, 2004) . Por exemplo, em um modelo com intercepto aleatório,  $\eta$  pode representar os interceptos individuais de cada sujeito, permitindo que cada um tenha sua própria linha de base (Kleinbaum & Klein, 2002; Rubin, 2006; Skrondal; Rabe-Hesketh, 2004).
- $\varepsilon$  representa os **erros residuais**, que descrevem a variação não explicada pelo modelo (Weisberg, 2024; Kleinbaum & Klein, 2002; Kutner et al., 2005). Esses erros são geralmente assumidos como independentes (Weisberg, 2024; Kutner et al, 2005) e identicamente distribuídos (Kutner et al, 2005; Kleinbaum & Klein, 2002), frequentemente seguindo uma distribuição normal com média zero e variância constante (Weisberg, 2024; Kleinbaum & Klein, 2002; Kutner et al., 2005; Bürkner & Vuorre, 2019)

Forma expandida para um exemplo com intercepto aleatório:

$$y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \cdots + \beta_p x_{ip} + b_{0j[i]} + \varepsilon_i$$

Onde:

- $y_i$ : valor observado para a  $i$ -ésima unidade;
- $\beta_0$ : intercepto fixo;
- $\beta_1, \dots, \beta_p$ : coeficientes fixos das covariáveis;
- $x_{i1}, \dots, x_{ip}$ : valores das covariáveis para a  $i$ -ésima unidade;
- $b_{0j[i]}$ : efeito aleatório do grupo  $j$  ao qual a unidade  $i$  pertence, com  $b_{0j} \sim \mathcal{N}(0, \sigma_b^2)$ ;
- $\varepsilon_i \sim \mathcal{N}(0, \sigma^2)$ : erro residual.

Essa formulação permite que os Modelos Lineares Mistos capturem tanto os padrões gerais dos dados (por meio dos efeitos fixos) quanto a variabilidade específica de cada unidade (por meio dos efeitos aleatórios), tornando-os particularmente úteis em contextos com dados hierárquicos ou medidas repetidas.

### 2.1.2. Modelos Relacionados e Extensões:

A **Análise de Variância (ANOVA)** é uma técnica que utiliza modelos lineares para comparar médias de diferentes tratamentos ou grupos (Eiselen & van Huyssteen, 2023; Rencher & Schaalje, 2008; Rubin, 2006). Embora muitas vezes apresentada como um método à parte, a ANOVA pode ser entendida como um caso especial de modelo de regressão linear, em que as variáveis preditoras são qualitativas (categóricas) (Kutner et al, 2005; Rencher & Schaalje, 2008). Essas variáveis são incluídas no modelo por meio de variáveis indicadoras, ou “dummies”, que representam cada categoria, exceto uma que é usada como referência (Weisberg, 2024; Kutner et al, 2005; Rencher & Schaalje, 2008).

Nesse contexto, o modelo linear geral da ANOVA permite decompor a variação total observada em duas partes principais: a variação explicada pelo modelo (soma dos quadrados do modelo, SSR) (Kutner et al., 2005) e a variação residual não explicada (soma dos quadrados dos erros, SSE) (Kutner et al., 2005; Kleinbaum & Klein, 2002). Essa estrutura facilita testes estatísticos para determinar se as médias dos grupos diferem significativamente (Eiselen & van Huyssteen, 2023; Kutner et al, 2005; Kleinbaum & Klein, 2002).

Ao analisar dados longitudinais com medidas repetidas, a ANOVA tradicional apresenta limitações devido às suposições rígidas sobre dados faltantes e à estrutura da variância-covariância (Rubin, 2006). Para superar essas restrições, a ANOVA pode ser estendida para modelos mistos que incluem efeitos aleatórios, como o efeito do sujeito, que representa a variabilidade individual entre os participantes ao longo do tempo (Rubin, 2006; Skrondal & Rabe-Hesketh, 2004; Liu & Agresti, 2005). Esse efeito aleatório é modelado como uma variável com distribuição normal, média zero e variância específica, permitindo capturar a correlação entre as medidas repetidas do mesmo indivíduo (Rubin, 2006; Liu & Agresti, 2005; Bauer & Sterba, 2011).

A incorporação do efeito aleatório do sujeito impõe uma estrutura de simetria composta na

matriz de variância-covariância, assumindo variâncias iguais ao longo do tempo e covariâncias constantes entre os diferentes momentos (Rubin, 2006). Em estudos mais complexos, com múltiplos grupos e medidas repetidas, outros efeitos aleatórios podem ser incluídos para representar variações dentro dos grupos e entre sujeitos aninhados, oferecendo uma modelagem mais adequada da dependência dos dados (Rubin, 2006; Liu & Agresti, 2005).

A **Análise de Covariância (ANCOVA)** combina modelos lineares típicos da análise de variância e da regressão (Kleinbaum & Klein, 2002; Rencher & Schaalje, 2008; Kutner et al, 2005). Um modelo geral de ANCOVA inclui preditores associados a efeitos fixos, como tratamentos em ANOVA, e preditores quantitativos, chamados covariáveis (Kleinbaum & Klein, 2002; Rencher & Schaalje, 2008; Kutner et al, 2005). Em certos contextos, um modelo que adiciona uma preditora contínua a um modelo de fator é chamado de análise de covariância, especialmente quando o foco está nas diferenças entre os níveis do fator (como diferentes tratamentos randomizados) (Weisberg, 2024).

Um modelo como  $y_{ij} = \gamma_{00} + \zeta_{0j} + \beta_1 x_{ij} + \varepsilon_{ij}$  é semelhante a um modelo convencional de ANCOVA, porém, a principal diferença está em considerar os  $\zeta_{0j}$  como efeitos aleatórios do fator (por exemplo, ‘escola’) em vez de efeitos fixos (Skrondal; Rabe-Hesketh, 2004).

Tratar um fator como aleatório é apropriado quando se deseja fazer inferências sobre uma população maior de fatores (como todas as escolas) (Skrondal; Rabe-Hesketh, 2004) pois o efeito do fator é representado por um único parâmetro — a variância — em vez de um parâmetro distinto para cada nível (Skrondal; Rabe-Hesketh, 2004). Assim, a ANCOVA pode ser interpretada e analisada como um modelo de regressão abrangente (Kutner et al, 2005; Seber & Lee, 2003).

**Os Modelos Lineares Generalizados (GLMs)** estendem o modelo linear clássico para acomodar diferentes tipos de variáveis resposta e distribuições (Kleinbaum & Klein, 2002; Kutner et al, 2005; Rubin, 2006; Freitas Costa, 2024; Rubin, 2006). Quando a variável resposta é contínua e aproximadamente normalmente distribuída, o GLM se reduz ao modelo linear padrão (Kleinbaum & Klein, 2002). Entretanto, quando a variável resposta contínua apresenta distribuição assimétrica, heterocedasticidade ou restrição a valores positivos, outros modelos dentro da estrutura dos GLMs são mais apropriados, como a regressão gama, regressão exponencial e regressão com distribuição Inversa Gaussiana (Kleinbaum & Klein, 2002; Kutner et al, 2005; Skrondal; Rabe-Hesketh, 2004; Bauer & Sterba, 2011)

Além disso, os GLMs podem ser expandidos para incluir efeitos mistos, ou seja, combinam efeitos fixos com efeitos aleatórios, possibilitando modelar dados com correlações intragrupos, como dados longitudinais ou hierarquizados (Freitas Costa, 2024; Skrondal; Rabe-Hesketh, 2004; Kleinbaum & Klein, 2002; Rubin, 2006; Liu & Agresti, 2005). Esses modelos são conhecidos como Modelos Lineares Mistos Generalizados (GLMMs) (Rabe-Hesketh, 2004; Kleinbaum & Klein, 2002; Liu & Agresti, 2005).

No contexto de resposta contínua, os GLMMs permitem capturar a variação entre unidades agrupadas (ex.: sujeitos, escolas) por meio de termos aleatórios (Liu & Agresti, 2005; Rabe-Hesketh, 2004), mantendo a flexibilidade para modelar a média da resposta via um preditor linear e função identidade (ligação padrão para dados contínuos) (Kleinbaum & Klein, 2002; Rabe-Hesketh, 2004; Kleinbaum & Klein, 2002; Liu & Agresti, 2005; Rubin, 2006). Isso possibilita a modelagem robusta de dados com estrutura de dependência e variabilidade complexa (Rabe-Hesketh, 2004; Rubin, 2006; Kleinbaum & Klein, 2002; Rubin, 2006).

### 2.1.3. Pressupostos da Regressão linear mista

Os pressupostos fundamentais da Regressão linear mista são extensões dos pressupostos da regressão linear tradicional, que são:

- **Normalidade dos Erros:** Assume-se que os erros aleatórios (resíduos) dentro de cada grupo ou tratamento seguem uma distribuição normal. Isso significa que a distribuição das diferenças entre cada observação e a média do seu grupo deve ser aproximadamente normal (Montgomery, 2017; Agresti, 2002).
- **Homocedasticidade (Variância Constante dos Erros):** Assume-se que a variância dos erros é constante em todos os grupos ou níveis do fator, ou seja a dispersão dos dados ao redor das médias dos grupos deve ser semelhante para todos os grupos (Montgomery, 2017; Agresti, 2002).
- **Independência dos Erros:** Assume-se que os erros associados a cada observação são independentes uns dos outros. Isso implica que o valor do erro para uma observação não deve influenciar o valor do erro para qualquer outra observação. A independência geralmente está relacionada à forma como os dados foram coletados (por exemplo, amostragem aleatória) (Montgomery, 2017; Agresti, 2002).
- **Especificação Correta da Estrutura de Covariância**  
É necessário especificar adequadamente a estrutura de correlação entre observações dentro do mesmo grupo (por exemplo, medidas repetidas). Estruturas comuns incluem intercepto aleatório, inclinação aleatória e autoregressiva. Uma estrutura mal especificada pode levar a estimativas viesadas e erros padrão incorretos (West et al., 2014; Singer & Willett, 2003).
- **Normalidade dos Efeitos Aleatórios:** Os efeitos aleatórios são assumidos como distribuídos normalmente  $b_j \sim \mathcal{N}(0, \tau^2)$ . Essa suposição é fundamental para a correta modelagem da variabilidade entre grupos ou sujeitos (Montgomery, 2017; Pinheiro & Bates, 2000).

A verificação dos pressupostos da Regressão linear mista é crucial para a validade das conclusões. A **análise de resíduos** é uma ferramenta fundamental para essa verificação. Os resíduos são as diferenças entre os valores observados e os valores preditos pelo modelo de

regressão linear (as médias dos grupos) (Montgomery, 2017; Agresti, 2002).

- **Gráficos de Resíduos:** Diversos gráficos podem ser utilizados para examinar os resíduos.
  - **Gráfico de Resíduos versus Valores Ajustados (*Fitted Values*):** Este gráfico é útil para verificar a homocedasticidade. Se a variância dos erros for constante, os resíduos devem apresentar uma dispersão aleatória e aproximadamente a mesma amplitude para todos os valores ajustados. Um padrão de “funil” (a dispersão aumentando ou diminuindo com os valores ajustados) pode indicar heterocedasticidade.
- **Testes de Normalidade e Homocedasticidade:** Testes estatísticos formais também podem ser usados para complementar a análise gráfica.
  - **Testes de Normalidade:** Existem vários testes para avaliar a normalidade dos resíduos, como o teste de Shapiro-Wilk, Kolmogorov-Smirnov e outros.
  - **Testes de Homocedasticidade:** Testes como o teste de Bartlett, Levene e Brown-Forsythe podem ser usados para testar a igualdade das variâncias dos erros entre os grupos.
- **Verificação da Estrutura de Covariância:** Para garantir que a estrutura de covariância esteja bem especificada, compare modelos com diferentes estruturas utilizando critérios de informação, como AIC (Critério de Informação Akaike; Akaike, 1974) e BIC (Critério de Informação Bayesiano; Schwarz, 1978). Além disso, realize testes de razão de verossimilhança (Likelihood Ratio Test) para verificar se estruturas mais complexas proporcionam um melhor ajuste (Pinheiro & Bates, 2000). Por fim, analise os resíduos em busca de padrões de autocorrelação que possam indicar uma má especificação da estrutura de correlação (Diggle et al., 2002).
- **Independência dos Erros:** Utilize gráficos dos resíduos ordenados por tempo ou pela sequência das observações para identificar possíveis padrões de autocorrelação. Além disso, testes formais, como o teste de Durbin-Watson (Durbin & Watson, 1950), podem ser aplicados para detectar correlação serial nos resíduos.

Se a análise de resíduos indicar violações significativas dos pressupostos da regressão linear, transformações de dados podem ser aplicadas à variável resposta para tentar tornar os dados mais adequados aos pressupostos do modelo (Montgomery, 2017; Agresti, 2002).

- **Transformações para Não Normalidade e Variâncias Desiguais:** Algumas transformações comuns incluem:
  - **Transformação Logarítmica:** Útil quando a variância aumenta com a média e para dados com assimetria positiva.
  - **Transformação Raiz Quadrada:** Usada frequentemente para dados de contagem ou quando a variância é proporcional à média.
  - **Transformação Inversa ( $1/Y$ ):** Pode ser útil quando a variância é proporcional ao



quadrado da média .

- **Transformação de Box-Cox:** É uma família de transformações de potência que pode ajudar a encontrar a transformação mais apropriada para normalizar os dados e estabilizar a variância.

É importante notar que a escolha da transformação deve ser baseada na natureza da violação dos pressupostos e no conhecimento sobre os dados. Após a transformação, a análise de resíduos deve ser refeita para verificar se os pressupostos foram atendidos de forma mais adequada (Montgomery, 2017; Agresti, 2002). Além disso, a interpretação dos resultados deve ser feita na escala dos dados transformados (Montgomery, 2017).

É de summa importância verificar a adequação do modelo e realizar a análise de resíduos após a aplicação da regressão. A não conformidade com os pressupostos pode afetar a validade dos testes de significância e das conclusões do modelo. No entanto, a regressão linear é considerada robusta contra pequenas ou moderadas violações da normalidade, especialmente com amostras grandes. A homocedasticidade é geralmente mais importante para a validade dos resultados (Rencher, 2008; Montgomery, 2017).

## 2.2. Modelo de Regressão Logística Ordinal

A regressão logística ordinal (OLR) é uma técnica estatística paramétrica adequada para analisar dados cuja variável resposta possui categorias naturalmente ordenadas (Eiselen & van Huyssteen, 2023; Kleinbaum & Klein, 2010; Kutner et al, 2005). Diferentemente da regressão logística binária, que trata de desfechos dicotômicos (duas categorias) (Kleinbaum & Klein, 2010), a OLR é empregada quando o desfecho tem três ou mais categorias que podem ser classificadas de forma ordenada (Kleinbaum & Klein, 2010; Kutner et al, 2005; Bürkner e Vuorre, 2019).

Essa metodologia tem sido amplamente utilizada em diversas áreas (Abreu et al, 2009; Rubin, 2006), como na análise de qualidade de vida por meio de escalas intervalares, em indicadores de condição de saúde e gravidade de doenças (Kutner et al, 2005; Abreu et al, 2009; Rubin, 2006) — onde os dados frequentemente assumem a forma de escores (Rubin, 2006). No nível de escolaridade (fundamental, médio, superior) ou a gravidade de uma doença (leve, moderada, grave). Nessas situações, embora as categorias tenham uma ordem, a diferença entre elas não é necessariamente mensurável em termos absolutos, como ocorre com variáveis contínuas (Costa Júnior, 2024; Bauer e Sterba, 2011) .

Outro exemplo é o de pesquisas de opinião (Costa Júnior et al, 2024), nas quais o pesquisado responde de 1 a 7, por exemplo, o que acham da saudabilidade de um alimento (Prates et al., 2022), sendo que 1 é nada saudável e 7 totalmente saudável. Nesses cenários, a OLR permite investigar como variáveis explicativas influenciam a probabilidade de um indivíduo pertencer a uma categoria ordinal mais alta ou mais baixa (Costa Júnior et al, 2024; Liddell e Kruschke,

2018).

O modelo de regressão logística ordinal mais comum é o **modelo de odds proporcionais**, também conhecido como modelo de *logit* cumulativo (Abreu et al. 2009, Kleinbaum & Klein, 2010). Esse modelo assume que a relação entre cada par de categorias adjacentes da variável dependente é a mesma, ou seja, que os coeficientes das variáveis independentes são constantes para todos os pontos de corte das categorias (Abreu et al. 2009, Kleinbaum & Klein, 2010, Kutner et al, 2005).

O objetivo central da OLR é modelar a relação entre um conjunto de variáveis preditoras (contínuas ou categóricas) e uma variável resposta ordinal (Eiselen e van Huyssteen, 2023). O modelo é ajustado a partir de dados amostrais para caracterizar essa relação. Assume-se que a variável resposta ordinal  $Y$ , com  $k$  categorias codificadas de 1 a  $K$ , é influenciada por um vetor de variáveis explicativas ou covariáveis (Kleinbaum & Klein, 2010).

Formalmente, o modelo logit acumulativo inverso pode ser expresso como:

$$\log \left( \frac{P(Y \geq j)}{P(Y < j)} \right) = \theta_j^* + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_k X_k$$

onde:

- $Y$  é a variável dependente ordinal com  $J$  categorias;
- $(j = 1, \dots, J - 1)$  representa os pontos de corte entre categorias;
- $\theta_j^*$  são os interceptos ou pontos de corte (*thresholds*);
- $\beta_1, \beta_2, \dots, \beta_k$  são os coeficientes das variáveis independentes  $X_1, X_2, \dots, X_k$ .

A interpretação dos coeficientes é similar à da regressão logística binária (Kleinbaum & Klein, 2010). A vantagem dessa modelo *logit* acumulativo inverso está na hora de interpretar seus resultados. A razão  $P(Y \geq j)/P(Y < j)$  representa as chances (*odds*) de o desfecho (variável  $Y$ ) estar na categoria  $j$  ou em uma categoria superior, em comparação com as chances de estar em uma categoria inferior a  $j$ , ou seja, na categoria  $j-1$  ou abaixo (Liu & Agresti, 2005). Como os coeficientes são constantes em todos os níveis da variável dependente, interpreta-se que o efeito da variável explicativa é o mesmo ao longo da escala ordinal da variável resposta (Kleinbaum & Klein, 2010, Kutner et al, 2005).

A suposição de *odds* proporcionais é crucial nesse modelo. Ela implica que a razão de chances (*odds ratio*) associada a uma mudança em uma variável independente é constante em todos os níveis da variável dependente (Abreu et al, 2009, Kleinbaum & Klein, 2010). Essa suposição pode ser testada e caso seja violada, existem modelos mais flexíveis que pode ser mais apropriados (Abreu et al, 2009).

Além da suposição de odds proporcionais, a regressão ordinal tradicional também assume que as observações são independentes entre si (Kleinbaum & Klein, 2010; Hedeker & Gibbons, 2006). No entanto, em situações onde essa independência não pode ser garantida, como em

estudos que envolvem dados agrupados ou estruturados, a regressão ordinal mista torna-se uma alternativa apropriada. A principal vantagem da regressão ordinal mista é que ela permite modelar a dependência entre as observações dentro de grupos ou clusters, ao incluir efeitos aleatórios. Esses efeitos aleatórios são capazes de capturar a variabilidade intra-grupo, considerando a estrutura hierárquica dos dados e oferecendo uma modelagem mais realista e robusta para situações em que as suposições de independência das observações não são atendidas (Fitzmaurice, Laird & Ware, 2011).

Os efeitos aleatórios acrescentam termos ao modelo, como interceptos ou inclinações que variam entre os grupos. Esses termos são assumidos como distribuídos normalmente,  $N(0, \sigma^2)$ , de forma que cada grupo introduz um “deslocamento” no preditor linear. A independência condicional é um pressuposto importante: uma vez considerados os efeitos aleatórios, as unidades dentro de um mesmo grupo são tratadas como condicionalmente independentes.

Dessa forma, a regressão logística ordinal mista permite modelar variáveis ordinais enquanto leva em consideração a estrutura de agrupamento dos dados, ajustando os efeitos fixos (variáveis explicativas) e aleatórios (variabilidade entre os grupos). A propriedade dos *odds* proporcionais condicionais, ou seja, a restrição de paralelismo se mantém para os coeficientes fixos do modelo, de maneira análoga ao modelo logit acumulativo simples. Isso melhora a precisão das estimativas e controla as correlações intra-grupo, proporcionando uma análise mais robusta e realista para dados que violam a suposição de independência das observações.

O ajuste do modelo pode ser avaliado por meio de medidas como o pseudo-  $R^2$  (como o de McFadden), o Critério de Informação de Akaike (AIC) e o teste de razão de verossimilhança para comparar modelos aninhados. Além disso, é possível examinar resíduos e medidas de influência para identificar possíveis problemas com o modelo (Kleinbaum & Klein, 2010).

No software **R**, o modelo pode ser ajustado usando a função `polr()` do pacote **MASS** ou `clm()` e `clmm()` do pacote **ordinal**. Outras linguagens como **Stata**, **SPSS** e **Python (via statsmodels)** também oferecem suporte a esse tipo de modelagem (Liddell & Krushke, 2018).

### 2.2.1. Interpretação dos Coeficientes $\beta$

No Modelo de *Odds* Proporcionais (MOP), os coeficientes  $\beta$  medem o efeito de uma covariável sobre o logaritmo da razão de chances acumulada (log-odds cumulativa). Especificamente, um aumento de uma unidade em  $X_i$ , mantendo as demais constantes, altera o logaritmo da razão de chances acumulada  $\frac{P(Y \geq j)}{P(Y < j)}$  em  $-\beta_i$  unidades.

A odds cumulativa para o ponto de corte  $j$  é dada por:

$$\text{Odds}(Y \geq j \mid X) = \frac{P(Y \geq j \mid X)}{P(Y < j \mid X)}$$

O modelo assume a seguinte forma funcional:

$$\text{Odds}(Y \geq j \mid X) = \exp(\theta^* + X^\top \beta)$$

Ou, de forma equivalente:

$$\log \left( \frac{P(Y \geq j \mid X)}{P(Y < j \mid X)} \right) = \theta^* + X^\top \beta$$

Onde:

- $\alpha_j$  é um parâmetro específico do ponto de corte  $j$ ;
- $\beta$  é um vetor de coeficientes comum a todos os pontos de corte, o que caracteriza a assunção de proporcionalidade das chances (proportional *odds*);
- O sinal negativo em  $+X^\top \beta$  implica que o efeito das covariáveis é constante em todos os cortes, mas atua reduzindo ou aumentando a chance de estar nas categorias superiores, dependendo do sinal de  $\beta$ .

### 2.2.2. Interpretação da Odds Ratio no Modelo de Odds Proporcionais (MOP)

A interpretação prática dos coeficientes de regressão  $\beta$  no Modelo de *Odds* Proporcionais (MOP) é facilitada por sua transformação em ***odds ratios* (OR)**, obtidas pela exponenciação:  $\text{OR} = \exp(\beta)$ .

A ***odds ratio*** representa o fator pelo qual a ***odds cumulativa*** se altera para uma mudança específica na variável preditora, mantendo todas as outras constantes. No MOP, assume-se que esse efeito (expresso pela OR) é constante para todos os pontos de corte da variável resposta ordinal. Em outras palavras, a razão de chances acumulada  $\frac{P(Y \geq j)}{P(Y < j)}$  muda pelo mesmo fator multiplicativo (a OR) para qualquer valor de  $j$ , quando a variável preditora aumenta uma unidade — ou quando passa do nível de referência para o nível de interesse, no caso de variáveis categóricas (Kleinbaum & Klein, 2010).

- Se  $\text{OR} > 1$  (isto é,  $\beta_i > 0$ ):

Um aumento na variável preditora está associado a um **aumento** na odds cumulativa  $\frac{P(Y \geq j)}{P(Y < j)}$ . Isso significa que a chance da resposta estar em uma **categoria maior ou igual a (j) aumenta**.

- Se  $\text{OR} < 1$  (isto é,  $\beta_i < 0$ ):

Um aumento na variável preditora está associado a uma **diminuição** na odds cumulativa, ou seja, a chance da resposta estar em uma **categoria maior ou igual a j diminui**. Nesse caso, aumenta a probabilidade de estar em uma **categoria mais baixa**.

Dependendo do tipo da variável preditora, a interpretação das odds ratios pode variar. As variáveis preditoras podem ser dicotômicas, contínuas, ordinais ou categóricas nominais, e a

interpretação das odds ratios muda conforme o tipo de variável:

### 1. Dicotômica (0 = referência, 1 = grupo de interesse):

- O coeficiente  $\beta_i$  está associado à comparação entre os dois grupos.
- A odds ratio  $OR_i = \exp(\beta_i)$  quantifica quanto a odds cumulativa no grupo 1 é maior (ou menor) que no grupo 0, mantendo as demais covariáveis constantes.
- Devido à suposição de *odds* proporcionais, essa OR é constante para todos os pontos de corte  $j$  da variável resposta ordinal.

### 2. Contínua ou Ordinal com 1 coeficiente

- Se uma variável contínua ou ordinal é incluída com um único coeficiente  $\beta_i$ , a *odds ratio*  $OR_i = \exp(\beta_i)$  indica o fator de mudança na odds cumulativa para cada **aumento de uma unidade** em  $X_i$ , mantendo as demais variáveis constantes.
- A suposição de odds proporcionais implica que essa OR é constante para todos os cortes  $j$ .
- Se  $\beta_i$  for pequeno ou a unidade de  $X_i$  pouco significativa (ex: 1 ano de idade), pode-se calcular  $\exp(\beta_i \times \Delta X_i)$  para interpretar variações maiores e mais úteis (ex: a cada 10 anos).

### 3. Categórica nominal (modelada com dummies)

- Cada dummy representa a comparação de uma categoria com o nível de referência.
- A OR de cada dummy  $OR_{i,dummy} = \exp(\beta_{i,dummy})$  expressa quanto a odds cumulativa daquela categoria difere da categoria de referência.
- Assim como nas outras variáveis, a OR é constante em todos os pontos de corte, desde que a suposição de odds proporcionais seja válida.

#### 2.2.3. Suposição de Odds Proporcionais

A suposição de odds proporcionais, também conhecida como suposição de regressão paralela, é uma premissa fundamental do Modelo de Odds Proporcionais (MOP) (Abreu et al., 2009; Kleinbaum & Klein, 2010). Essa suposição afirma que o efeito de cada variável explicativa sobre a razão de chances acumuladas é constante entre os pontos de corte da variável resposta (Abreu et al., 2009; Kleinbaum & Klein, 2010). Em outras palavras, assume-se que a relação entre as covariáveis e a probabilidade de a resposta estar em uma categoria inferior, comparada às superiores, é a mesma para cada ponto de separação entre as categorias (Long & Frees, 2006).

Por exemplo, suponha que a variável resposta possua três categorias ordenadas: “baixo”, “médio” e “alto”. A suposição de odds proporcionais implica que a razão de chances associada a uma covariável — como a presença de uma determinada exposição — será a mesma ao comparar as categorias “baixo” versus “médio ou alto” e “baixo ou médio” versus “alto”. Assim,

os coeficientes estimados para as covariáveis são constantes ao longo dessas comparações, refletindo uma única linha de tendência para o efeito de cada variável preditora.

Essencialmente, a suposição de odds proporcionais estabelece que o efeito de cada covariável (variável explicativa) sobre a razão de chances acumuladas é constante ao longo de todos os pontos de corte das categorias da variável resposta ordinal. Em um modelo de odds proporcionais, são considerados  $(k - 1)$  pontos de corte das categorias, baseados na comparação de probabilidades acumuladas. A suposição implica que a relação entre as covariáveis e a probabilidade de a resposta estar em uma categoria inferior, comparada às superiores, é a mesma para cada ponto de separação entre as categoria(Kleinbaum & Klein, 2010).

No MOP, cada covariável incluída no modelo assume essa suposição. Isso resulta em um único parâmetro (coeficiente beta) para cada variável preditora, que representa seu efeito consistente em todos os logitos cumulativos (pontos de corte). Para uma variável resposta com  $G$  categorias, há  $G - 1$  interceptos diferentes ( $\theta^*$ ), um para cada ponto de corte, mas um único coeficiente ( $\beta$ ) para cada variável preditora que não depende do índice  $j$  da categoria. Isso significa que a relação entre as covariáveis e a variável resposta é independente da categoria, o que é interpretado graficamente como retas de regressão paralelas. A razão de chances (OR) para qualquer duas categorias de uma covariável será a mesma independentemente do ponto de corte utilizado para dicotomizar a variável resposta.

A verificação dessa suposição é crucial para a validade do modelo de odds proporcionais (Abreu et al., 2009). A violação da suposição de odds proporcionais pode levar a viés de estimação de efeitos e a inferências incorretas (Agresti, 2010; Bauer; Sterba, 2011; Sasidharan & Menéndez, 2014). O principal teste estatístico empregado é o teste *escore* (*score test*) (Abreu et al., 2009; Kleinbaum & Klein, 2010), que compara o modelo com restrição de odds proporcionais ao modelo politômico (ou multinomial), que não impõe essa restrição (Long & Frees, 2006). A hipótese nula do teste é a de que a suposição de odds proporcionais é válida. Um valor-p elevado sugere que não há evidência suficiente para rejeitar a suposição, enquanto um valor-p baixo indica sua violação. Contudo, a não rejeição da hipótese nula não garante que a suposição esteja de fato correta, pois o teste pode não ter poder estatístico suficiente, especialmente em amostras pequenas.

Um teste amplamente utilizado na prática para essa verificação é o teste de Brant, que pode ser considerado uma extensão do teste *escore*. O teste de Brant compara os coeficientes estimados em modelos logísticos binários separados (um para cada ponto de corte da variável resposta) com os coeficientes do MOP, que assume a constância dos efeitos das covariáveis. A hipótese nula é a de que os coeficientes são iguais em todos os pontos de corte, ou seja, que a suposição de odds proporcionais é válida (Kleinbaum & Klein, 2010). Um valor-p elevado sugere que não há evidência suficiente para rejeitar a suposição, enquanto um valor-p baixo indica sua violação (Kleinbaum & Klein, 2010; Preisser et al., 2010). Contudo, a não rejeição da hipótese nula não garante que a suposição esteja de fato correta, pois o teste pode não ter

poder estatístico suficiente, especialmente em amostras pequenas (Skron dal & Rabe-hesketh, 2004; Preisser et al., 2010).

Além do teste escore e do teste de Brant, podem ser utilizados gráficos de resíduos parciais para avaliar visualmente a validade da suposição. Esses gráficos permitem observar a linearidade das covariáveis e o paralelismo das curvas de regressão associadas às diferentes categorias da resposta. Em um modelo que respeita a suposição de odds proporcionais, espera-se que essas curvas sejam aproximadamente paralelas e lineares. No entanto, desvios acentuados dessas características — como diferenças acentuadas nas inclinações entre categorias — sugerem a presença de violação da suposição (Abreu et al., 2009; Bauer & Sterba, 2011; Liu & agresti, 2005).

Por fim, é importante destacar que tanto o teste escore quanto os métodos gráficos devem ser usados de forma complementar. A interpretação dos resultados exige cautela e conhecimento do contexto, uma vez que a decisão de manter ou abandonar o MOP pode ter implicações substanciais na análise e nas conclusões do estudo.

#### 2.2.4. Modelos Alternativos à OLR com MOP

Quando a suposição de odds proporcionais não é atendida, existem outros modelos que podem ser utilizados (Abreu et al., 2009):

- **Modelo de Odds Proporcionais Parciais (MOPP):** Permite que algumas variáveis satisfaçam a suposição de odds proporcionais, enquanto outras não. Para estas, coeficientes distintos são estimados para cada ponto de corte.
- **Modelo de Razão Contínua (MRC):** Compara a probabilidade de estar em uma categoria específica com a de estar em categorias superiores. Pode ser ajustado como um conjunto de regressões logísticas binárias.
- **Modelo Estereótipo (ME):** Derivado da regressão multinomial, impõe uma estrutura linear aos coeficientes por meio de pesos atribuídos às categorias. É útil quando a ordenação das categorias é discreta, mas importante.
- **Modelos Cumulativos com Variável Latente (CM):** Assumem que a variável ordinal é resultado da discretização de uma variável contínua latente. A distribuição dessa variável (logística, normal, etc.) define o tipo de modelo, como o ordered probit.

### 3. METODOLOGIA

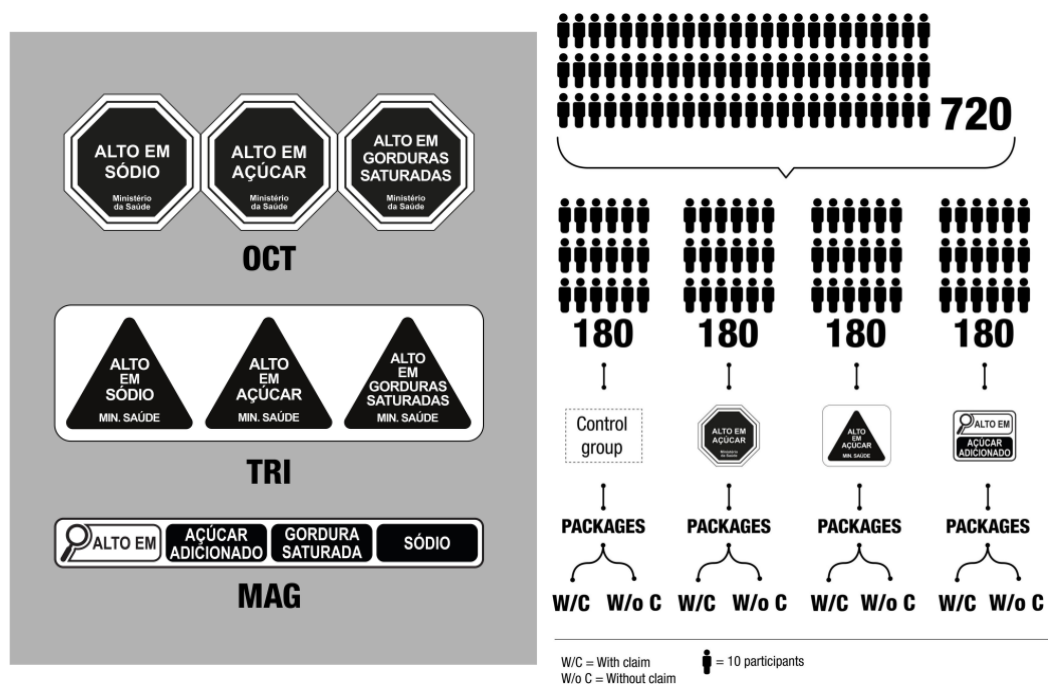
O banco de dados utilizado para a Análise de Variância (ANOVA) e a Regressão Logística Ordinal é o mesmo empregado no estudo de Prates et al. (2022), intitulado “Influência das alegações nutricionais em diferentes modelos de rotulagem nutricional frontal de alimentos supostamente saudáveis: Impacto na compreensão da informação nutricional, percepção de saudabilidade e intenção de compra de consumidores brasileiros”.

O principal objetivo da pesquisa apresentada no referido artigo foi avaliar a influência das alegações nutricionais na eficácia de diferentes modelos de rotulagem nutricional frontal (RNF). Especificamente, o estudo comparou o modelo de lupa, implementado no Brasil (Brasil, 2020) com dois modelos de advertência; o modelo octogonal, implementado no Chile, e o modelo triangular, anteriormente proposto à Agência Nacional de Vigilância Sanitária (ANVISA), baseado nos critérios da legislação chilena (Ministério de Salud Chile, 2015). A eficácia desses modelos foi analisada com base em seu impacto na compreensão da informação nutricional, na percepção de saudabilidade dos consumidores brasileiros (Prates et al., 2022).

#### 3.1. Participantes e Desenho Experimental

O estudo contou com 720 participantes brasileiros com 18 anos ou mais, selecionados com base em cotas de sexo, região, nível socioeconômico e escolaridade (IBGE, 2022). A coleta foi feita online via computador, entre dezembro de 2021 e fevereiro de 2022, excluindo profissionais das áreas de alimentos e nutrição. Todos os participantes consentiram voluntariamente.

Figura 1: Modelos de rotulagem nutricional frontal testados no estudo e alocação dos participantes e alocação dos participantes nas condições de intervenção do estudo





Fonte: Prates et al. (2022).

Trata-se de um estudo experimental e transversal, que avaliou das alegações nutricionais na na eficácia de diferentes modelos de rotulagem nutricional frontal (RNF) — octógono, triângulo e lupa — sobre a compreensão da informação nutricional, a percepção de saudabilidade de alimentos (Figura 1).

Os participantes foram distribuídos aleatoriamente em quatro grupos: controle (sem RNF), OCT, octógono; TRI, triângulo e MAG, lupa, sendo cada grupo com 180 participantes (Figura 1). Cada indivíduo avaliou 12 painéis frontais de rótulos, com base nas combinações: (i) categoria do produto (barra de cereal, biscoito integral, snack); (ii) quantidade de nutrientes em excesso (1 ou 2 nutrientes); (iii) alegações nutricionais (presença e ausência) (Figura 2).

Figura 2: Combinação de fatores considerados para o desenvolvimento do rótulo: categoria de alimento (barra de cereal, snack e biscoito); tipo de produto (contendo 1 ou 2 nutrientes em excesso); alegação nutricional (presente vs. ausente).



Fonte: Prates et al. (2022).

Todos os participantes visualizaram os mesmos rótulos de alimentos, variando apenas quanto ao modelo de RNF. A escolha das três categorias de alimentos se deu pelo seu apelo de opções de lanches “saudáveis” e devido ao potencial da RNF em modificar a percepção equivocada de saudabilidade desses produtos. O experimento seguiu um delineamento em quadrado latino, minimizando efeitos de ordem e fadiga.

### 3.2. Procedimento experimental

O questionário da pesquisa foi estruturado em quatro etapas. Na primeira, foram coletadas informações pessoais dos participantes, como peso, altura, responsabilidade pelas compras no domicílio e frequência de consumo dos produtos avaliados. Os dados sociodemográficos — sexo, idade, região geográfica, nível socioeconômico e escolaridade — não foram coletados diretamente, pois já estavam disponíveis na base de dados da empresa responsável pela pesquisa. Na segunda etapa, os participantes foram expostos individualmente os 12 rótulos de alimentos, apresentados conforme um delineamento do tipo quadrado latino. Após cada exposição, os participantes respondiam uma pergunta sobre a composição nutricional do produto, para avaliar a compreensão da informação, e em seguida indicavam, por meio de escalas de Likert de 7 pontos, o quão saudável consideravam o produto, variando de 1 (“não saudável”) a 7 (“muito saudável”).

A terceira etapa foi direcionada exclusivamente aos grupos que visualizaram os modelos de RNF — octógono, triângulo e lupa. Esses participantes responderam a oito questões relacionadas à visibilidade, clareza, credibilidade e outros aspectos do respectivo modelo, com base em uma escala de sete pontos adaptada de Khandpur et al. (2020). Por fim, na quarta etapa, todos os participantes responderam ao questionário *General Health Interest*, traduzido e validado para o Português (Soares et al., 2006) uma subescala das *Health and Taste Attitude Scales* (Roininen et al., 1999), composta por oito itens que avaliam o interesse do consumidor por alimentação saudável, também por meio de uma escala Likert de sete pontos.

### 3.3. Análise dos dados

Para avaliar a percepção de saudabilidade, foi ajustado um Modelo Linear Generalizado Misto (GLMM), replicando as análises previamente realizadas no estudo original (PRATES et al., 2022). Além disso, propôs-se, nesta monografia, a aplicação de um Modelo Logístico Ordinal Misto como (MLOM) uma nova abordagem.

A equação do modelo de regressão linear ajustado com a função `lme()`, do pacote `nlme`, é dada por:

$$\begin{aligned}
Y_i = & \beta_0 + \beta_1 \text{GR\_RNF}_1 + \beta_2 \text{GR\_RNF}_2 + \beta_3 \text{GR\_RNF}_3 + \beta_4 \text{CAT}_1 + \beta_5 \text{CAT}_2 \\
& + \beta_6 \text{ALG}_1 + \beta_7 \text{NUT}_2 + \beta_8 (\text{GR\_RNF}_1 \times \text{CAT}_1) + \beta_9 (\text{GR\_RNF}_2 \times \text{CAT}_1) \\
& + \beta_{10} (\text{GR\_RNF}_3 \times \text{CAT}_1) + \beta_{11} (\text{GR\_RNF}_1 \times \text{CAT}_2) + \beta_{12} (\text{GR\_RNF}_2 \times \text{CAT}_2) \\
& + \beta_{13} (\text{GR\_RNF}_3 \times \text{CAT}_2) + \beta_{14} (\text{GR\_RNF}_1 \times \text{NUT}_2) + \beta_{15} (\text{GR\_RNF}_2 \times \text{NUT}_2) \\
& + \beta_{16} (\text{GR\_RNF}_3 \times \text{NUT}_2) + \beta_{17} (\text{GR\_RNF}_1 \times \text{ALG}_1) + \beta_{18} (\text{GR\_RNF}_2 \times \text{ALG}_1) \\
& + \beta_{19} (\text{GR\_RNF}_3 \times \text{ALG}_1) + \beta_{20} (\text{CAT}_1 \times \text{NUT}_2) + \beta_{21} (\text{CAT}_2 \times \text{NUT}_2) \\
& + \beta_{22} (\text{NUT}_2 \times \text{ALG}_1) + \beta_{23} (\text{CAT}_1 \times \text{ALG}_1) + \beta_{24} (\text{CAT}_2 \times \text{ALG}_1) \\
& + \beta_{25} (\text{CAT}_1 \times \text{NUT}_2 \times \text{ALG}_1) + \beta_{26} (\text{CAT}_2 \times \text{NUT}_2 \times \text{ALG}_1) \\
& + \beta_{27} (\text{GR\_RNF}_1 \times \text{NUT}_2 \times \text{ALG}_1) + \beta_{28} (\text{GR\_RNF}_2 \times \text{NUT}_2 \times \text{ALG}_1) \\
& + \beta_{29} (\text{GR\_RNF}_3 \times \text{NUT}_2 \times \text{ALG}_1) + \beta_{30} (\text{GR\_RNF}_1 \times \text{CAT}_1 \times \text{NUT}_2) \\
& + \beta_{31} (\text{GR\_RNF}_2 \times \text{CAT}_1 \times \text{NUT}_2) + \beta_{32} (\text{GR\_RNF}_3 \times \text{CAT}_1 \times \text{NUT}_2) \\
& + \beta_{33} (\text{GR\_RNF}_1 \times \text{CAT}_2 \times \text{NUT}_2) + \beta_{34} (\text{GR\_RNF}_2 \times \text{CAT}_2 \times \text{NUT}_2) \\
& + \beta_{35} (\text{GR\_RNF}_3 \times \text{CAT}_2 \times \text{NUT}_2) + u_i + \epsilon_i
\end{aligned}$$

Onde:

- $Y_i$  é a variável dependente SAUDABILIDADE para a observação  $i$ ,
- $\beta_0$  é o intercepto,
- $\beta_1, \beta_2, \dots, \beta_{53}$  são os coeficientes associados às variáveis explicativas,
- $u_i$  é o efeito aleatório associado ao agrupamento por  $ID_i$ ,
- $\epsilon_i$  é o erro residual para a observação  $i$ .

A equação do modelo acumulativo ordinal misto ajustado com a função `c1mm()`, do pacote `ordinal`, é dada por:

$$\begin{aligned}
Y_i = & \theta_1 + \theta_2 + \theta_3 + \theta_5 + \theta_6 - \left( \beta_1 \text{GR\_RNF}_1 + \beta_2 \text{GR\_RNF}_2 + \beta_3 \text{GR\_RNF}_3 + \beta_4 \text{CAT}_1 + \beta_5 \text{CAT}_2 \right. \\
& + \beta_6 \text{ALG}_1 + \beta_7 \text{NUT}_2 + \beta_8 (\text{GR\_RNF}_1 \times \text{CAT}_1) + \beta_9 (\text{GR\_RNF}_2 \times \text{CAT}_1) \\
& + \beta_{10} (\text{GR\_RNF}_3 \times \text{CAT}_1) + \beta_{11} (\text{GR\_RNF}_1 \times \text{CAT}_2) + \beta_{12} (\text{GR\_RNF}_2 \times \text{CAT}_2) \\
& + \beta_{13} (\text{GR\_RNF}_3 \times \text{CAT}_2) + \beta_{14} (\text{GR\_RNF}_1 \times \text{NUT}_2) + \beta_{15} (\text{GR\_RNF}_2 \times \text{NUT}_2) \\
& + \beta_{16} (\text{GR\_RNF}_3 \times \text{NUT}_2) + \beta_{17} (\text{GR\_RNF}_1 \times \text{ALG}_1) + \beta_{18} (\text{GR\_RNF}_2 \times \text{ALG}_1) \\
& + \beta_{19} (\text{GR\_RNF}_3 \times \text{ALG}_1) + \beta_{20} (\text{CAT}_1 \times \text{NUT}_2) + \beta_{21} (\text{CAT}_2 \times \text{NUT}_2) \\
& + \beta_{22} (\text{NUT}_2 \times \text{ALG}_1) + \beta_{23} (\text{CAT}_1 \times \text{ALG}_1) + \beta_{24} (\text{CAT}_2 \times \text{ALG}_1) \\
& + \beta_{25} (\text{CAT}_1 \times \text{NUT}_2 \times \text{ALG}_1) + \beta_{26} (\text{CAT}_2 \times \text{NUT}_2 \times \text{ALG}_1) \\
& + \beta_{27} (\text{GR\_RNF}_1 \times \text{NUT}_2 \times \text{ALG}_1) + \beta_{28} (\text{GR\_RNF}_2 \times \text{NUT}_2 \times \text{ALG}_1) \\
& + \beta_{29} (\text{GR\_RNF}_3 \times \text{NUT}_2 \times \text{ALG}_1) + \beta_{30} (\text{GR\_RNF}_1 \times \text{CAT}_1 \times \text{NUT}_2) \\
& + \beta_{31} (\text{GR\_RNF}_2 \times \text{CAT}_1 \times \text{NUT}_2) + \beta_{32} (\text{GR\_RNF}_3 \times \text{CAT}_1 \times \text{NUT}_2) \\
& + \beta_{33} (\text{GR\_RNF}_1 \times \text{CAT}_2 \times \text{NUT}_2) + \beta_{34} (\text{GR\_RNF}_2 \times \text{CAT}_2 \times \text{NUT}_2) \\
& \left. + \beta_{35} (\text{GR\_RNF}_3 \times \text{CAT}_2 \times \text{NUT}_2) + b_{\text{ID}(i)} \right)
\end{aligned}$$

onde:

- $Y_i$  é a variável dependente SAUDABILIDADE para a observação  $i$ ,
- $\theta_k$ : limiares (*thresholds*) para as categorias.
- $\beta_1, \beta_2, \dots, \beta_{53}$ : coeficientes de efeitos fixos.
- $b_{ID(i)} \sim N(0, \sigma^2)$ : intercepto aleatório para o ID.

As variáveis principais dos dois modelos foram: Grupo RNF (GR RNF), Categoria do Alimento (CAT), Alegação (ALG) e Quantidade de nutrientes em excesso (NUT), além de suas interações. Essas interações permitiram investigar efeitos combinados entre os fatores, fornecendo uma análise mais refinada da percepção de saudabilidade. As variáveis demográficas, como Região, Gênero, Cota de idade, Escolaridade e Renda, não foram incluídas uma vez que não apresentaram diferença entre grupos.

O experimento utilizou um planejamento do tipo quadrado latino, considerando dois fatores de bloco: os participantes e a ordem de apresentação das 12 combinações de produtos. Como cada um dos 720 participantes respondeu a múltiplas observações, o efeito dos participantes foi incorporado ao modelo como um efeito aleatório, por meio do identificador individual (ID).

Após o ajuste do modelo linear mista, realizou-se uma análise de variância (ANOVA) utilizando a função `anova()` para identificar diferenças estatisticamente significativas entre os grupos. Quando o p valor foi inferior a 5% (0,05), aplicou-se o teste de comparações múltiplas de Tukey, por meio da função `glht()`, para determinar quais grupos apresentavam diferenças significativas entre si.

Para o ajuste do modelo logístico ordinal misto, utilizou-se a função `emmeans()`, do pacote do mesmo nome, para calcular as estimativas marginais dos grupos. Em modelos de regressão logística, essas estimativas correspondem aos efeitos ajustados dos grupos na escala do modelo (*log-odds*). Quando identificadas diferenças estatisticamente significativas ( $p < 0,05$ ), aplicou-se o teste de comparações múltiplas de Tukey, com ajuste para múltiplas comparações, para determinar quais grupos diferiam significativamente entre si. As comparações foram expressas em termos de diferenças de *odds ratios*.

Todas as análises realizadas foram feitas utilizando o software RStudio, versão 4.4.1.

## 4. RESULTADOS

### 4.1. Regressão Linear Mista

A Tabela 1 apresenta os resultados apresentados na tabela mostram os testes F e os respectivos p-valores para os efeitos principais e os termos de interação incluídos no modelo linear misto. A análise dos resultados da Análise de Variância (ANOVA) apresentada na Tabela 1 traz revelações importantes sobre os fatores que influenciaram a percepção de saudabilidade.

Os resultados da ANOVA indicam **efeitos principais estatisticamente significativos** para todas as variáveis independentes avaliadas ( $p\text{-valor} < 0.05$ ).

Tabela 1: Resultado da Análise de Variância (ANOVA) para Saudabilidade

Variável	numDF	F-value	p-value
Grupo RNF	3	92.6701	<b>&lt;0.001</b>
Categoria alimento	2	6.3678	<b>0.0017</b>
Nutriente em Excesso	1	500.0619	<b>&lt;0.001</b>
Alegação	1	92.4407	<b>&lt;0.001</b>
Grupo RNF:Categoria alimento	6	1.6455	0.1303
Grupo RNF:Nutriente em Excesso	3	26.1328	<b>&lt;0.001</b>
Grupo RNF:Alegação	3	0.6952	0.5549
Categoria alimento:Nutriente em Excesso	2	2.8298	0.0591
Categoria alimento:Alegação	2	1.8322	0.1601
Nutriente em Excesso:Alegação	1	2.8644	0.0906
Grupo RNF:Categoria alimento:Nutriente em Excesso	6	0.4650	0.8347
Grupo RNF:Categoria alimento:Alegação	6	1.3401	0.2353
Grupo RNF:Nutriente em Excesso:Alegação	3	3.4649	<b>0.0155</b>
Categoria alimento:Nutriente em Excesso:Alegação	2	1.8841	0.152

*Fonte: Elaboração própria.*

A Tabela 2 apresenta as pontuações médias de saudabilidade por categoria de alimento. Os resultados revelaram poucas diferenças entre os grupos (Tabela 2). As médias observadas foram: barra de cereal com média de 3,91 (IC 95% : 3,83-3,99); biscoito com médias de 3,99 (IC 95% : 3,91-4,07); e snack com média de 3,98 (IC 95% : 3,90-4,05).

Tabela 2: Pontuações médias de saudabilidade por categoria de Alimento

Efeito	Média SAUDABILIDADE (IC 95%)
Categoria de alimentos	
Barra de cereal	3.91 (3.83, 3.99)
Biscoito	3.99 (3.91, 4.07)
Snack	3.98 (3.9, 4.05)

Fonte: Elaboração própria.

A análise de variância indicou diferenças estatisticamente entre as categorias de alimentos ( $p=0,0017$ ) (Tabela 1), sugerindo que pelo menos uma das categorias difere das demais em relação à saudabilidade. No entanto, as comparações múltiplas realizadas, por meio do teste de Tukey, não identificaram diferenças estatisticamente significativas entre os pares de categorias ao nível de 5% de significância (Tabela 3).

Tabela 3: Resultados das Comparações Pós-Hoc entre Categoria de alimento

Comparação	Estimativa	IC.95.	P.Valor
Biscoito - Barra de cereal	0.157	(-0.01 ; 0.32)	0.154
Snack - Barra de cereal	0.114	(-0.05 ; 0.28)	0.374
Snack - Biscoito	-0.043	(-0.21 ; 0.12)	0.867

Fonte: Elaboração própria.

Tabela 4: Pontuações médias saudabilidade por Grupo RNF X Nutrientes em excesso X Alegações nutricionais

Grupo RNF	1 nutriente em excesso		2 nutrientes em excesso	
	Ausência	Presença	Ausência	Presença
Controle	5.68 (5.55, 5.8)	5.79 (5.67, 5.91)	5.43 (5.3, 5.56)	5.76 (5.64, 5.87)
Octógono	3.38 (3.21, 3.56)	3.61 (3.44, 3.79)	2.92 (2.74, 3.09)	3.09 (2.92, 3.26)
Triângulo	3.41 (3.25, 3.57)	3.6 (3.44, 3.76)	2.84 (2.68, 3)	2.98 (2.82, 3.14)
Lupa	3.92 (3.77, 4.08)	3.99 (3.84, 4.15)	3.35 (3.19, 3.5)	3.58 (3.42, 3.74)

Fonte: Elaboração própria.

A Tabela 4 apresenta as pontuações médias de saudabilidade percebida, com intervalo de confiança de 95%, segundo o tipo RNF, quantidade de nutriente em excesso e presença e alegações de alegações nutricionais. Os resultados revelam que a adoção de modelos de rotulagem nutricional frontal (RNF) – Octógono, Triângulo e Lupa – tem impacto significativo na forma como os consumidores percebem a saudabilidade de produtos com um ou dois nutrientes críticos em excesso (Tabela 5). De modo geral, todos os modelos de rotulagem

testados foram eficazes em reduzir a percepção de saudabilidade dos produtos, especialmente em comparação ao grupo controle, que não apresentava nenhum tipo de advertência no rótulo.

Tabela 5: Resultados das Comparações Pós-Hoc das interações Grupo RNF X Quantidade de nutrientes em excesso X Alegação

Alegação	Nutriente em excesso	Comparação	Estimativa	IC.95.	P.Valor
Presença	1 nutriente	Octógono - Controle	-2.178	(-2.52 ; -1.83)	0.000
Presença	1 nutriente	Triângulo - Controle	-2.193	(-2.54 ; -1.85)	0.000
Presença	1 nutriente	Lupa - Controle	-1.798	(-2.15 ; -1.45)	0.000
Presença	1 nutriente	Triângulo - Octógono	-0.015	(-0.36 ; 0.33)	1.000
Presença	1 nutriente	Lupa - Octógono	0.380	(0.03 ; 0.73)	0.139
Presença	1 nutriente	Lupa - Triângulo	0.394	(0.05 ; 0.74)	0.116
Presença	2 nutrientes	Octógono - Controle	-2.667	(-3.02 ; -2.32)	0.000
Presença	2 nutrientes	Triângulo - Controle	-2.778	(-3.13 ; -2.43)	0.000
Presença	2 nutrientes	Lupa - Controle	-2.178	(-2.53 ; -1.83)	0.000
Presença	2 nutrientes	Triângulo - Octógono	-0.111	(-0.46 ; 0.24)	0.924
Presença	2 nutrientes	Lupa - Octógono	0.489	(0.14 ; 0.84)	0.031
Presença	2 nutrientes	Lupa - Triângulo	0.600	(0.25 ; 0.95)	0.004
Ausência	1 nutriente	Octógono - Controle	-2.296	(-2.64 ; -1.95)	0.000
Ausência	1 nutriente	Triângulo - Controle	-2.274	(-2.62 ; -1.93)	0.000
Ausência	1 nutriente	Lupa - Controle	-1.757	(-2.1 ; -1.41)	0.000
Ausência	1 nutriente	Triângulo - Octógono	0.022	(-0.32 ; 0.37)	0.999
Ausência	1 nutriente	Lupa - Octógono	0.539	(0.19 ; 0.88)	0.012
Ausência	1 nutriente	Lupa - Triângulo	0.517	(0.17 ; 0.86)	0.017
Ausência	2 nutrientes	Octógono - Controle	-2.511	(-2.87 ; -2.16)	0.000
Ausência	2 nutrientes	Triângulo - Controle	-2.585	(-2.94 ; -2.23)	0.000
Ausência	2 nutrientes	Lupa - Controle	-2.080	(-2.44 ; -1.72)	0.000
Ausência	2 nutrientes	Triângulo - Octógono	-0.074	(-0.43 ; 0.28)	0.977
Ausência	2 nutrientes	Lupa - Octógono	0.431	(0.08 ; 0.79)	0.081
Ausência	2 nutrientes	Lupa - Triângulo	0.506	(0.15 ; 0.86)	0.027

Fonte: Elaboração própria.

As diferenças entre os grupos foram estatisticamente significativas em praticamente todos os cenários, com p-valores  $< 0,05$  nas comparações entre os modelos de RNF e o grupo controle. Esse resultado sugere que a simples presença de um rótulo de advertência já é suficiente para alterar a percepção do consumidor, mesmo quando há alegações nutricionais no produto.

A Tabela 5 apresenta os resultados das comparações Pós-Hoc da interação Grupo RNF x quantidade de nutrientes em excesso x alegações. Ao comparar os diferentes tipos de rotulagem, observou-se que os modelos Octógono e Triângulo apresentaram efeitos similares, com diferenças não significativas entre si na maioria das condições testadas. Isso indica que ambos os modelos possuem desempenho semelhante na redução da percepção de saudabilidade.

Já o modelo da Lupa apresentou resultados mais variados: embora também tenha reduzido a percepção de saudabilidade em relação ao grupo controle; em alguns cenários ele foi percebido como menos impactante, mostrando diferenças significativas, quando comparado ao Octógono e ao Triângulo, especialmente em situações com apenas um nutriente em excesso e na ausência de alegações nutricionais. Esse resultado pode sugerir que a Lupa transmite uma mensagem menos contundente ao consumidor, podendo comprometer parcialmente sua efetividade como ferramenta de saúde pública, comparado aos dois modelos de advertência.

A presença de alegações nutricionais nos rótulos não foi suficiente para neutralizar o efeito da RNF, mas em certos contextos ela parece atenuar a redução na percepção de saudabilidade, particularmente no caso da Lupa. Ainda assim, os dados indicam que os rótulos frontais mantêm sua efetividade mesmo na presença de alegações, reforçando seu potencial como instrumento de orientação ao consumidor.



#### 4.2. Regressão Logística Ordinal Mista

A Tabela 6 apresenta os resultados da regressão logística ordinal aplicada para modelar a percepção de saudabilidade dos produtos, considerando os efeitos principais e interações de até terceira ordem. Optou-se por limitar as interações até a terceira ordem devido à alta complexidade e à dificuldade de convergência do modelo ao incluir interações de quarta ordem.

Tabela 6: Resultado da Regressão logística Ordinal para Saudabilidade

Variáveis	P.Valor
Grupo RNF	< 0.0001
Categoria alimento	< 0.0001
Nutrientes em excesso	< 0.0001
Alegação	< 0.0001
Categoria alimento:Nutrientes em excesso	< 0.0001
Categoria alimento:Alegação	< 0.0001
Nutrientes em excesso:Alegação	< 0.0001
Grupo RNF:Nutrientes em excesso	< 0.0001
Grupo RNF:Categoria alimento	< 0.0001
Grupo RNF:Alegação	< 0.0001
Categoria alimento:Nutrientes em excesso:Alegação	< 0.0001
Grupo RNF:Nutrientes em excesso:Alegação	< 0.0001
Grupo RNF:Categoria alimento:Alegação	0.002
Grupo RNF:Categoria alimento:Nutrientes em excesso	< 0.0001

*Fonte: Elaboração própria.*

Todos os efeitos listados — principais e interações — apresentaram p valores < 0,05, o que indica que todos os quatros fatores estudados têm associação estatisticamente significativa com a percepção de saudabilidade (Tabela 6). Isso inclui tanto os efeitos individuais quanto as combinações entre variáveis (interações de segunda e terceira ordem).

As Tabela 7, Tabela 8 e Tabela 9 apresentam os resultados das comparações entre os modelos de rótulos frontais (Grupo RNF), a quantidade de nutrientes em excesso, a presença de alegações nutricionais para cada categoria de produto (Snack, Biscoito e Barra de cereal, respectivamente).

Ao avaliar o produto snack (Tabela 7), observa-se que, em todas as combinações entre presença ou ausência de alegações nutricionais e quantidade de nutrientes em excesso (1 ou 2 nutrientes), a ausência de rotulagem frontal (condição controle) aumenta significativamente as chances de o produto ser percebido como mais saudável em comparação aos modelos com rotulagem de advertência (Octógono, Triângulo ou Lupa).

Por exemplo, considerando produtos com 1 nutriente em excesso e presença de alegações

nutricionais, a comparação entre o modelo Controle vs. Octógono resulta em uma razão de odds (OR) de 8,38 (IC95%: 5,62–12,5), indicando que os participantes que não visualizaram o rótulo (Controle) tiveram uma chance mais de 8 vezes maior de considerar o snack mais saudável em relação àqueles que visualizaram o rótulo octogonal.

Tabela 7: Resultados das comparações entre Grupos RNF, considerando a presença ou ausência de alegação nutricional e a quantidade de nutrientes em excesso (1 ou 2) em produtos da categoria Snack

Alegação	Nutriente em excesso	Comparações	OR	IC95% OR	p-valor
Presença	1 nutriente	Controle - Octógono	8.380	(5.62 ; 12.5)	<0.001
Presença	1 nutriente	Controle - Triângulo	8.321	(5.63 ; 12.3)	<0.001
Presença	1 nutriente	Controle - Lupa	6.217	(4.25 ; 9.09)	<0.001
Presença	1 nutriente	Octógono - Triângulo	0.993	(0.68 ; 1.44)	1
Presença	1 nutriente	Octógono - Lupa	0.742	(0.51 ; 1.07)	0.381
Presença	1 nutriente	Triângulo - Lupa	0.747	(0.52 ; 1.07)	0.382
Presença	2 nutrientes	Controle - Octógono	11.612	(7.73 ; 17.44)	<0.001
Presença	2 nutrientes	Controle - Triângulo	12.531	(8.4 ; 18.68)	<0.001
Presença	2 nutrientes	Controle - Lupa	6.998	(4.77 ; 10.27)	<0.001
Presença	2 nutrientes	Octógono - Triângulo	1.079	(0.74 ; 1.57)	0.978
Presença	2 nutrientes	Octógono - Lupa	0.603	(0.42 ; 0.87)	0.0381
Presença	2 nutrientes	Triângulo - Lupa	0.558	(0.39 ; 0.8)	0.00878
Ausência	1 nutriente	Controle - Octógono	11.295	(7.53 ; 16.94)	<0.001
Ausência	1 nutriente	Controle - Triângulo	9.127	(6.15 ; 13.54)	<0.001
Ausência	1 nutriente	Controle - Lupa	6.317	(4.31 ; 9.27)	<0.001
Ausência	1 nutriente	Octógono - Triângulo	0.808	(0.56 ; 1.17)	0.675
Ausência	1 nutriente	Octógono - Lupa	0.559	(0.39 ; 0.81)	0.0106
Ausência	1 nutriente	Triângulo - Lupa	0.692	(0.48 ; 0.99)	0.184
Ausência	2 nutrientes	Controle - Octógono	11.750	(7.82 ; 17.66)	<0.001
Ausência	2 nutrientes	Controle - Triângulo	10.898	(7.34 ; 16.18)	<0.001
Ausência	2 nutrientes	Controle - Lupa	6.898	(4.71 ; 10.1)	<0.001
Ausência	2 nutrientes	Octógono - Triângulo	0.927	(0.64 ; 1.35)	0.98
Ausência	2 nutrientes	Octógono - Lupa	0.587	(0.4 ; 0.85)	0.0278
Ausência	2 nutrientes	Triângulo - Lupa	0.633	(0.44 ; 0.91)	0.0631

Fonte: *Elaboração própria.*

Ao comparar entre os diferentes modelos de rotulagem, ainda na presença de alegações nutricionais e com 1 nutriente em excesso, não foram encontradas diferenças estatisticamente significativas entre o rótulo com lupa e os demais modelos: Octógono vs. Lupa ( $p = 0,381$ ) e Triângulo vs. Lupa ( $p = 0,382$ ).

Contudo, quando há 2 nutrientes em excesso, os rótulos octogonal e triangular se mostraram mais eficazes do que o modelo com lupa em reduzir a percepção de saúde do produto. Especificamente, o rótulo octógono reduziu em cerca de 39,7% a chance de o snack ser

percebido como mais saudável em comparação à lupa (OR = 0,603;  $p = 0,038$ ), e o triângulo, em cerca de 44,2% (OR = 0,558;  $p = 0,0087$ ). Esse padrão também foi observado na ausência de alegações nutricionais. Mesmo com apenas 1 nutriente em excesso, o rótulo octógono reduziu em aproximadamente 44,1% a chance de o snack ser considerado saudável em comparação ao rótulo com lupa (OR = 0,559;  $p = 0,0106$ ).

Tabela 8: Resultados das comparações entre grupos RNF, considerando a presença ou ausência de alegação nutricional e a quantidade de nutrientes em excesso (1 ou 2) em produtos da categoria Biscoito

Alegação	Nutriente em excesso	Comparações	OR	IC95% OR	p-valor
Presença	1 nutriente	Controle - Octógono	9.006	(6.05 ; 13.41)	<0.001
Presença	1 nutriente	Controle - Triângulo	9.526	(6.41 ; 14.16)	<0.001
Presença	1 nutriente	Controle - Lupa	6.602	(4.49 ; 9.71)	<0.001
Presença	1 nutriente	Octógono - Triângulo	1.058	(0.73 ; 1.53)	0.991
Presença	1 nutriente	Octógono - Lupa	0.733	(0.51 ; 1.05)	0.337
Presença	1 nutriente	Triângulo - Lupa	0.693	(0.48 ; 1)	0.194
Presença	2 nutrientes	Controle - Octógono	14.699	(9.72 ; 22.24)	<0.001
Presença	2 nutrientes	Controle - Triângulo	15.411	(10.22 ; 23.23)	<0.001
Presença	2 nutrientes	Controle - Lupa	8.723	(5.89 ; 12.93)	<0.001
Presença	2 nutrientes	Octógono - Triângulo	1.048	(0.72 ; 1.52)	0.995
Presença	2 nutrientes	Octógono - Lupa	0.593	(0.41 ; 0.86)	0.028
Presença	2 nutrientes	Triângulo - Lupa	0.566	(0.39 ; 0.81)	0.0118
Ausência	1 nutriente	Controle - Octógono	10.149	(6.8 ; 15.16)	<0.001
Ausência	1 nutriente	Controle - Triângulo	10.104	(6.8 ; 15.02)	<0.001
Ausência	1 nutriente	Controle - Lupa	5.878	(4.01 ; 8.61)	<0.001
Ausência	1 nutriente	Octógono - Triângulo	0.996	(0.69 ; 1.44)	1
Ausência	1 nutriente	Octógono - Lupa	0.579	(0.4 ; 0.84)	0.0185
Ausência	1 nutriente	Triângulo - Lupa	0.582	(0.41 ; 0.83)	0.0174
Ausência	2 nutrientes	Controle - Octógono	11.205	(7.48 ; 16.78)	<0.001
Ausência	2 nutrientes	Controle - Triângulo	10.691	(7.2 ; 15.87)	<0.001
Ausência	2 nutrientes	Controle - Lupa	6.284	(4.3 ; 9.18)	<0.001
Ausência	2 nutrientes	Octógono - Triângulo	0.954	(0.65 ; 1.39)	0.995
Ausência	2 nutrientes	Octógono - Lupa	0.561	(0.39 ; 0.82)	0.013
Ausência	2 nutrientes	Triângulo - Lupa	0.588	(0.41 ; 0.85)	0.0217

Fonte: Elaboração própria.

Ao avaliar o produto biscoito (Tabela 8), observa-se que, também, em todas as combinações entre presença ou ausência de alegações nutricionais e quantidade de nutrientes em excesso (1 ou 2 nutrientes), a ausência de rotulagem frontal (condição controle) aumenta significativamente as chances de o produto ser percebido como mais saudável em comparação aos modelos com rotulagem de advertência (Octógono, Triângulo ou Lupa).

Por exemplo, considerando produtos com 2 nutriente em excesso e presença de alegações

nutricionais, a comparação entre o modelo Controle vs. Triângulo resulta em uma razão de odds (OR) de 15,411 (IC95%: 10,22–23,23), indicando que os participantes que não visualizaram o rótulo (Controle) tiveram uma chance mais de 15,5 vezes maior de considerar o biscoito mais saudável em relação àqueles que visualizaram o rótulo Triângulo (Tabela 8).

Tabela 9: Resultados das comparações entre grupos RNF, considerando a presença ou ausência de alegação nutricional e a quantidade de nutrientes em excesso (1 ou 2) em produtos da categoria Barra de cereal

Alegação	Nutriente em excesso	Comparações	OR	IC95% OR	p-valor
Presença	1 nutriente	Controle - Octógono	8.621	(5.8 ; 12.82)	<0.001
Presença	1 nutriente	Controle - Triângulo	8.221	(5.57 ; 12.14)	<0.001
Presença	1 nutriente	Controle - Lupa	5.398	(3.7 ; 7.88)	<0.001
Presença	1 nutriente	Octógono - Triângulo	0.954	(0.66 ; 1.38)	0.994
Presença	1 nutriente	Octógono - Lupa	0.626	(0.43 ; 0.9)	0.06
Presença	1 nutriente	Triângulo - Lupa	0.657	(0.46 ; 0.94)	0.1
Presença	2 nutrientes	Controle - Octógono	12.082	(8.07 ; 18.08)	<0.001
Presença	2 nutrientes	Controle - Triângulo	12.599	(8.43 ; 18.82)	<0.001
Presença	2 nutrientes	Controle - Lupa	7.192	(4.89 ; 10.58)	<0.001
Presença	2 nutrientes	Octógono - Triângulo	1.043	(0.72 ; 1.51)	0.996
Presença	2 nutrientes	Octógono - Lupa	0.595	(0.41 ; 0.86)	0.0302
Presença	2 nutrientes	Triângulo - Lupa	0.571	(0.4 ; 0.82)	0.0146
Ausência	1 nutriente	Controle - Octógono	7.879	(5.3 ; 11.72)	<0.001
Ausência	1 nutriente	Controle - Triângulo	8.131	(5.52 ; 11.98)	<0.001
Ausência	1 nutriente	Controle - Lupa	4.856	(3.33 ; 7.07)	<0.001
Ausência	1 nutriente	Octógono - Triângulo	1.032	(0.71 ; 1.49)	0.998
Ausência	1 nutriente	Octógono - Lupa	0.616	(0.43 ; 0.89)	0.0494
Ausência	1 nutriente	Triângulo - Lupa	0.597	(0.42 ; 0.85)	0.0247
Ausência	2 nutrientes	Controle - Octógono	9.208	(6.19 ; 13.7)	<0.001
Ausência	2 nutrientes	Controle - Triângulo	9.974	(6.72 ; 14.8)	<0.001
Ausência	2 nutrientes	Controle - Lupa	5.866	(4.02 ; 8.55)	<0.001
Ausência	2 nutrientes	Octógono - Triângulo	1.083	(0.74 ; 1.58)	0.976
Ausência	2 nutrientes	Octógono - Lupa	0.637	(0.44 ; 0.92)	0.0798
Ausência	2 nutrientes	Triângulo - Lupa	0.588	(0.41 ; 0.85)	0.0234

Fonte: *Elaboração própria.*

Ao comparar entre os diferentes modelos de rotulagem, ainda na presença de alegações nutricionais e com 1 nutriente em excesso, não foram encontradas diferenças estatisticamente significativas entre o rótulo com lupa e os demais modelos: Octógono vs. Lupa ( $p = 0,337$ ) e Triângulo vs. Lupa ( $p = 0,194$ ). No entanto, quando há 2 nutrientes em excesso, os rótulos octógono e triângulo se mostraram mais eficazes do que o modelo com lupa em reduzir a percepção de saúde do produto. O rótulo octógono reduziu em cerca de 40,7% a chance de o biscoito ser percebido como mais saudável em comparação à lupa (OR = 0,593;  $p = 0,028$ ),

e o triângulo, em cerca de 43,4% (OR = 0,566;  $p = 0,0118$ ). Já para a ausência de alegações nutricionais. Com 1 ou 2 nutriente em excesso, tanto o rótulo octógono quanto o triângulo diminuíram a chance de o biscoito ser percebido como saudável em relação a lupa.

Ao avaliar o produto barra de cereal (Tabela 9), observa-se que, em todas as combinações entre presença ou ausência de alegações nutricionais e quantidade de nutrientes em excesso (1 ou 2 nutrientes), a ausência de rotulagem frontal (condição controle) aumenta significativamente as chances de o produto ser percebido como mais saudável, em comparação aos modelos com rotulagem de advertência (Octógono, Triângulo ou Lupa).

Por exemplo, considerando produtos com 2 nutrientes em excesso e ausência de alegações nutricionais, a comparação entre o modelo Controle vs. Lupa resulta em uma razão de odds (OR) de 5,866 (IC95%: 4,02–8,55), indicando que os participantes que não visualizaram o rótulo (Controle) tiveram uma chance quase 5,8 vezes maior de considerar a barra de cereal mais saudável em relação àqueles que visualizaram o rótulo Lupa (Tabela 9).

Ao comparar os diferentes modelos de rotulagem (Tabela 9), ainda na presença de alegações nutricionais e com 1 nutriente em excesso, foram encontradas diferenças somente a comparação Triângulo vs. Lupa (OR = 0,657;  $p = 0,01$ ), ou seja, o rótulo Triângulo reduziu em cerca de 34,3% a chance de a barra de cereal ser percebida como mais saudável em comparação à Lupa. Por outro lado, quando há 2 nutrientes em excesso, os rótulos Octógono e Triângulo se mostraram mais eficazes do que o modelo com Lupa em reduzir a percepção de saúde do produto. O rótulo Octógono reduziu em cerca de 40,5% a chance de a barra de cereal ser percebida como saudável em comparação à Lupa (OR = 0,595;  $p = 0,0302$ ), e o Triângulo, em cerca de 42,9% (OR = 0,571;  $p = 0,0146$ ). Já na ausência de alegações nutricionais, tanto com 1 quanto com 2 nutrientes em excesso, os rótulos Octógono e Triângulo também reduziram significativamente a


## 5. DISCUSSÃO

### 5.1. Regressão Linear Mista

A aparente divergência entre os resultados da ANOVA (Tabela 1) e do teste de Tukey (Tabela 3) pode ser explicada pela natureza distinta dos testes (Eiselen & van Huyssteen, 2023), pela sobreposição dos intervalos de confiança (Montgomery, 2017) e pelo fato de se tratar de uma variável ordinal, cuja análise por métodos paramétricos baseados em médias pode não captar adequadamente nuances na distribuição dos dados. Enquanto a ANOVA detecta diferenças globais (Tabela 1), avaliando se há variação significativa entre as médias de todos os grupos, o teste de Tukey é mais conservador (Tabela 3), ajustando o nível de significância para controlar o erro do tipo I em múltiplas comparações e, por isso, é menos sensível a variações sutis entre pares de grupos.

Como esperado, a aplicação Modelos Lineares Mistos (MLMs) que assume normalidade e homocedasticidade a uma variável resposta não contínua violou esses pressupostos (Figura 3). Embora a regressão linear possa ser relativamente robusta a pequenos desvios da normalidade, especialmente em amostras grandes (Montgomery, 2017; Kutner et al., 2004), essa robustez é limitada e não se aplica quando a variável analisada não possui natureza contínua, como é o caso de variáveis ordinais. A presença de desvios significativos da normalidade, observados na Figura 3, pode afetar a validade dos testes de hipóteses, comprometendo os níveis de significância ( $\alpha$ ) e a potência dos testes, levando a conclusões equivocadas. Montgomery (2017) ressalta que modelos de efeitos aleatórios são mais sensíveis à não normalidade do que modelos de efeitos fixos, pois as inferências dependem da variância dos efeitos aleatórios. Dado que o modelo em questão é misto, a interpretação dos resultados requer ainda maior cautela (Montgomery, 2017; Kutner et al., 2004).

Figura 3: Análise de resíduos do Glm - Normalidade e Homoscedasticidade



A violação da homocedasticidade (heteroscedasticidade) também é um problema (Figura 3), pois pode levar a testes de hipóteses não confiáveis e estimativas imprecisas da variância dos erros, afetando a validade das conclusões. A violação da homoscedasticidade na ANOVA contribuiu para a perda de significância estatística de alguns resultados (Eiselen & Van Huyssteen, 2023).

Embora a transformação da variável dependente possa ser utilizada para contornar a violação de algumas suposições do modelo, como normalidade e homocedasticidade (Montgomery, 2017; Kutner et al., 2004), essa prática não é recomendada para variáveis ordinais. Não existe uma transformação capaz de converter uma variável ordinal, dado que ela é uma escala de likert, em uma distribuição normal sem comprometer sua natureza. Aplicar técnicas desenvolvidas para

dados contínuos ou proporcionais em variáveis ordinais pode distorcer a relação ordinal dos dados e comprometer a interpretação dos resultados. Essa abordagem inadequada pode gerar erros sistemáticos, como falsos positivos ou a não detecção de efeitos relevantes (Liddell & Kruschke, 2018).

Uma alternativa possível seriam os testes não paramétricos, como o teste de Kruskal-Wallis, que é uma alternativa à ANOVA para comparação entre grupos independentes. No entanto, esses testes geralmente não se estendem com facilidade à estrutura de modelos mistos que incluem efeitos aleatórios e múltiplas covariáveis de confusão. Por outro lado, os modelos paramétricos apresentam maior complexidade, justamente por permitirem a modelagem simultânea de efeitos fixos e da variabilidade entre grupos por meio dos efeitos aleatórios (Abreu et al., 2009).

Ao tratar dados ordinais como se fossem intervalares (ou métricos) na regressão linear, há um risco significativo de erros de interpretação, como falsos positivos, falsos negativos e até mesmo inversão de efeitos (Liddell & Kruschke, 2018). Um falso positivo (erros tipo I) ocorre quando o modelo indica a existência de um efeito que, na realidade, não existe. Isso pode acontecer, por exemplo, quando as médias latentes subjacentes são iguais, mas as médias ordinais observadas diferem significativamente. Esse erro pode surgir quando há desvios padrão latentes distintos entre dois grupos, de forma que o mapeamento sigmoidal para a escala ordinal resulta em médias diferentes, mesmo sem diferença real nas médias latentes. O modelo métrico, ao ignorar essa estrutura ordinal, pode então superestimar o tamanho do efeito (Burkner & Vuorre, 2019).

Por outro lado, podem ocorrer falsos negativos (erros tipo II), quando o modelo falha em detectar um efeito que realmente existe. Isso acontece quando duas condições apresentam médias ordinais semelhantes, mas, na verdade, possuem médias latentes diferentes. Nesse caso, o modelo linear pode não captar a diferença real entre os grupos. No contexto deste estudo, esse tipo de erro ocorreu ao não identificar diferenças reais entre os tipos de produtos analisados, resultado que foi detectado na abordagem específica para dados ordinais, a regressão logística ordinal (Burkner & Vuorre, 2019; Liddell & Kruschke, 2018).

## 5.2. Regressão Logística Ordinal Mista

O modelo de regressão ordinal utilizado assume o pressuposto de *Odds* Proporcionais (modelo paralelo), ou seja, considera que o efeito de cada covariável é constante para todas as comparações cumulativas da variável resposta. Dessa forma, a *Odds Ratio* (OR) que compara a probabilidade de estar em uma categoria inferior versus uma categoria superior permanece a mesma ao longo de todos os pontos de corte da escala ordinal.

No entanto, ao realizar o Teste de Brant para avaliar a suposição de *odds* proporcionais, o resultado indicou uma rejeição da hipótese nula ( $p < 0,0001$ ), evidenciando a violação dessa suposição no modelo ajustado. Isso sugere que o uso do Modelo de *Odds* Proporcionais (MOP) padrão pode não ser o mais adequado, indicando a necessidade de considerar modelos

alternativos, como o Modelo de Odds Proporcionais Parciais (MOPP), que flexibiliza essa suposição.

Uma limitação prática, contudo, foi identificada: o R não disponibiliza um comando direto para aplicar o Teste de Brant em modelos mistos, com efeitos aleatórios. A realização do teste em um modelo simplificado, sem considerar esses efeitos, pode comprometer as conclusões, visto que a inclusão dos efeitos aleatórios altera as estimativas dos coeficientes fixos, justamente os parâmetros avaliados pelo teste.

Apesar da violação do pressuposto de *odds* proporcionais, optou-se por manter o Modelo de Odds Proporcionais com Efeitos Aleatórios na análise. Essa decisão foi baseada em três fatores principais que são a adequação ao tipo de dado, a variável resposta é ordinal, proveniente de uma escala de Likert, o que justifica a utilização de modelos logísticos ordinais, em detrimento de abordagens lineares inadequadas. O Ganhos da Estrutura Hierárquica, Efeitos Aleatórios, a estrutura dos dados demanda a consideração de efeitos aleatórios, recurso que é adequadamente contemplado por modelos mistos. Embora modelos alternativos, como o MOPP, o Modelo de Razão Contínua (MRC) ou o Logit ordenado generalizado, flexibilizem a suposição de *odds* proporcional, eles aceitam a inclusão de efeitos aleatórios apenas em abordagens bayesianas, via pacotes como brms (Tabela 10), o que não é o foco desta monografia.

Tabela 10: Informações sobre os principais modelos de regressão logística ordinal, indicação de uso e pacotes R

Modelo	Efeito Aleatório	Odds Proporcional	Pacotes no R
Odds Proporcionais - MOP	Sim	Sim	ordinal::clmm, brms
Odds Proporcionais Parciais - MOPP	Sim	Parcial	brms
Razão Contínua - MRC	Sim	Não exige OP	brms
Estereótipo - ME	Não	Não exige OP	VGAM
Logit ordenado generalizado	Sim	Não exige OP	brms

Fonte: *Elaboração própria.*

Por fim, a interpretação parcimoniosa das *Odds Ratios* (ORs) é o principal benefício do Modelo de Odds Proporcionais (MOP), pois permite uma compreensão direta e consistente dos efeitos. Quando a suposição de *odds* proporcionais é válida, uma única OR resume o impacto da variável explicativa em toda a escala ordinal. Por exemplo, uma OR de 2,0 indica que, a cada incremento de uma unidade na variável preditora, as chances de estar em uma categoria superior na escala são o dobro das chances de permanecer em uma categoria inferior, mantendo-se esse efeito constante em todos os pontos de corte da escala Likert.

Além disso, ainda que o modelo logístico ordinal com todas as interações de ordem 3 tenha se mostrado significativo nas três combinações avaliadas, sendo plausível que o modelo com interação de ordem 4 também apresentasse significância, limitações do pacote ordinal e da função clmm impediram a convergência adequada do modelo de ordem 4, resultando em



estimativas com valores NA. A tentativa de utilizar a função `clmm2`, uma versão anterior, também não teve sucesso, resultando em uma hessiana excessivamente elevada e coeficientes indefinidos. Diante dessas dificuldades, optou-se por manter o modelo de ordem 3, que, apesar das limitações, apresentou interações mais significativas que o modelo linear.

## 6. CONCLUSÃO

O estudo concluiu que, apesar das limitações relacionadas à validação dos pressupostos estatísticos e às ferramentas de *software* disponíveis, a regressão logística ordinal mista mostrou-se uma abordagem vantajosa e mais adequada para a modelagem de variáveis ordinais, especialmente na presença de estrutura hierárquica nos dados. A prática recorrente de tratar variáveis ordinais como intervalares para aplicar métodos que resultam em comparação de médias, como a regressão linear mista, revela-se inadequada, uma vez que viola pressupostos fundamentais de normalidade e homocedasticidade. Além disso, a transformação de escala não é recomendada, pois pode distorcer a natureza ordinal dos dados e conduzir a interpretações equivocadas ou à perda de resultados relevantes, além de dificultar a interpretação dos resultados. Quando utilizamos a escala de Likert como variável contínua — como ocorre na regressão linear — a interpretação dos coeficientes depende fortemente da escala adotada no estudo, o que pode levar a inferências imprecisas sobre o impacto das estimativas.

A regressão logística ordinal mista é particularmente indicada para a variável “percepção de saudabilidade”, já que respeita a ordenação das categorias. Mesmo com a violação do pressuposto de *odds* proporcionais, optou-se por essa abordagem pelas vantagens na avaliação dos efeitos, pelo modelo parcimonioso, pelas *odds ratios* facilmente interpretáveis e pelas possibilidades de considerar a organização hierárquica nas medidas. A não adoção de alternativas, como o modelo de *odds* proporcionais parciais ou o modelo multinível categórico, deu-se pelas limitações de *software*, pelo maior grau de complexidade envolvido na especificação dos modelos e pelo escopo do estudo. É importante destacar a pertinência de futuros estudos que implementem esses métodos, aumentando as possibilidades de investigação de diferentes configurações de modelos ordinais na inferência, principalmente com a adição de efeitos aleatórios.

Em termos de resultados, tanto a regressão linear mista quanto a logística ordinal mista indicaram que a adoção de modelos de Rotulagem Nutricional Frontal (octógono, triângulo e lupa) afeta significativamente a percepção de saudabilidade dos produtos, aumentando a avaliação de que eles serão classificados como “pouco saudáveis” pelos consumidores — principalmente na presença de nutrientes em excesso. A presença de alegações nutricionais pode confundir o consumidor e diminuir o efeito de ver os 3 tipos de rótulos frontais - Octógono, triângulo e lupa - em relação a não ver uma RNF (Controle). Comparando os modelos, o octógono e o triângulo se destacaram como sendo os que mais influenciaram essa avaliação, enquanto o modelo lupa produziu um impacto menor na redução da percepção de saudabilidade. A presença de um rótulo de advertência, por si só, já se mostrou suficiente para modificar a avaliação do consumidor, sendo que o modelo ordinal se mostrou capaz de detectar tanto os efeitos principais quanto o efeito das interações que o modelo linear não capturou.

Em suma, os resultados reforçam a eficácia das estratégias de rotulagem frontal na

comunicação de riscos e na promoção de escolhas alimentares mais saudáveis pelos consumidores, sendo um importante instrumento de apoio às políticas públicas na área da nutrição. O estudo proporciona uma contribuição relevante tanto para o debate metodológico quanto para a formulação de medidas regulatórias, mostrando caminhos para a avaliação robusta de desfechos ordinais e para a compreensão de como diferentes rótulos influenciam a percepção da saudabilidade de alimentos.

## 7. REFERÊNCIA

- AGRESTI, A. *Analysis of Ordinal Categorical Data*. 2nd ed. Hoboken: Wiley-Interscience, 2010.
- AGRESTI, A. *Categorical Data Analysis*. 3rd ed. Hoboken, NJ: John Wiley & Sons, 2013.
- AKAIKE, H. A new look at the statistical model identification. *IEEE Transactions on Automatic Control*, 19(6), p. 716–723, 1974.
- BAUER, D. J.; STERBA, S. K. Fitting multilevel models with ordinal outcomes: performance of alternative specifications and methods of estimation. *Psychological Methods*, v. 16, n. 4, p. 373–390, 2011. DOI: 10.1037/a0025813.
- BÜRKNER, Paul-Christian; VUORRE, Matti. Ordinal regression models in psychology: a tutorial. *Advances in Methods and Practices in Psychological Science*, v. 2, n. 1, p. 77–101, 2019. DOI: 10.1177/2515245918823199.
- COSTA JÚNIOR, João Florêncio da; CABRAL, Eric Lucas dos Santos; SOUZA, Rosana Curvelo de; BEZERRA, Diogo de Menezes Cortês; SILVA, Polyana Tenório de Freitas e. Um estudo sobre o uso da escala de Likert na coleta de dados qualitativos e sua correlação com as ferramentas estatísticas. *Revista Convergência*, v. 17, n. 1, p. xx-xx, 2024. DOI: 10.55905/revconv.17n.1-021.
- DIGGLE, P. J.; HEAGERTY, P.; LIANG, K.-Y.; ZEGER, S. L. *Analysis of longitudinal data*. 2nd ed. Oxford University Press, 2002.
- DURBIN, J.; WATSON, G. S. Testing for serial correlation in least squares regression I. *Biometrika*, v. 37, n. 3-4, p. 409–428, 1950.
- EISELEN, Roald; VAN HUYSSSTEEN, Gerhard B. A Comparison of Statistical Tests for Likert-Type Data: The Case of Swearwords. *Journal of Open Humanities Data*, v. 9, p. 1–13, 2023. DOI: 10.5334/johd.132.
- FIELD, A. *Discovering Statistics Using IBM SPSS Statistics*. 5th ed. London: SAGE, 2017.
- FITZMAURICE, G. M.; LAIRD, N. M.; WARE, J. H. *Applied Longitudinal Analysis*. Wiley, 2011.
- FREITAS SOUZA, R. de; LIMA, F. G.; CORRÊA, H. L. Multilevel ordinal logit models: a proportional odds application using data from Brazilian higher education institutions. *Axioms*, Basel, v. 13, n. 1, p. 47, 2024. DOI: 10.3390/axioms13010047.
- GELMAN, Andrew; HILL, Jennifer. *Data Analysis Using Regression and Multilevel/Hierarchical Models*. Cambridge: Cambridge University Press, 2007.
- HEDEKER, D.; GIBBONS, R. D. *Longitudinal data analysis*. Hoboken: John Wiley & Sons, 2006.

- HOX, Joop; MOERBEEK, Mirjam; VAN DE SCHOOT, Rens. *Multilevel Analysis: Techniques and Applications*. 3. ed. New York: Routledge, 2017.
- JAMES, G.; WITTEN, D.; HASTIE, T.; TIBSHIRANI, R. *An Introduction to Statistical Learning*. 2nd ed. New York: Springer, 2021.
- KLEINBAUM, D. G.; KLEIN, Mitchel. *Logistic Regression: A Self-Learning Text*. 3rd ed. New York: Springer, 2010.
- KLEINBAUM, David G.; KUPPER, L. L.; NIZAM, A.; ROSENBERG, E. S. *Applied Regression Analysis and Other Multivariable Methods*. 5th ed. Boston: Cengage, 2013.
- KUTNER, Michael H.; NACHTSHEIM, Christopher J.; NETER, John; LI, William. *Applied Linear Statistical Models*. 5th ed. Boston: McGraw-Hill, 2004.
- LAVIELLE, Marc; BLEAKLEY, Kevin (contrib.). *Mixed Effects Models for the Population Approach: Models, Tasks, Methods and Tools*. Boca Raton: CRC Press, Taylor & Francis Group, 2015. ISBN 978-1-4822-2651-5.
- LIU, Ivy; AGRESTI, Alan. The analysis of ordered categorical data: an overview and a survey of recent developments. *Test*, México, v. 14, n. 1, p. 1–73, 2005.
- LIDDELL, Torrin M.; KRUSCHKE, John K. Analyzing ordinal data with metric models: What could possibly go wrong? *Journal of Experimental Social Psychology*, v. 79, p. 328–348, 2018. DOI: 10.1016/j.jesp.2018.08.009.
- LONG, J. S.; FREES, E. W. *Regression Models for Categorical Dependent Variables Using Stata*. College Station: Stata Press, 2006.
- MINISTERIO DE SALUD CHILE. Decreto 13/2015 - Modifica decreto supremo n\_ 977, de 1996, reglamento sanitario de los alimentos. (2015). Disponível em: <https://www.bcn.cl/leychile/navegar?i=1078836>
- MONTGOMERY, D. C. *Design and Analysis of Experiments*. 9th ed. Hoboken, NJ: John Wiley & Sons, 2017.
- PINHEIRO, J. C.; BATES, D. M. *Mixed-Effects Models in S and S-PLUS*. Springer, 2000.
- PREISSER, John S.; PHILLIPS, Ceib; PERIN, Jamie; SCHWARTZ, Todd A. Partial proportional odds models for longitudinal ordinal data. University of North Carolina at Chapel Hill. Department of Biostatistics Technical Report Series, Paper 15, 2010. Disponível em: <http://biostats.bepress.com/uncbiostat/art15>.
- RENCER, Alvin C.; SCHAALJE, G. Bruce. *Linear Models in Statistics*. 2nd ed. Hoboken: John Wiley & Sons, 2008.
- RUBIN, Donald B. *Matched Sampling for Causal Effects*. Cambridge: Cambridge University Press, 2006.
- SCHWARZ, G. Estimating the dimension of a model. *Annals of Statistics*, 6(2), p. 461–464,

1978.

SEARLE, S. R.; CASELLA, G.; MCCULLOCH, C. E. *Variance Components*. New York: Wiley, 1992.

SEBER, George A. F.; LEE, Alan J. *Linear regression analysis*. 2nd ed. Hoboken, NJ: John Wiley & Sons, 2003.

SKRONDAL, Anders; RABE-HESKETH, Sophia. *Generalized Latent Variable Modeling: Multilevel, Longitudinal, and Structural Equation Models*. Boca Raton: Chapman & Hall/CRC, 2004.

SNIJDERS, Tom A. B.; BOSKER, Roel J. *Multilevel Analysis: An Introduction to Basic and Advanced Multilevel Modeling*. 2nd ed. Thousand Oaks: Sage Publications, 2012.

SOARES LLS, DELIZA R, GONÇALVES EB. Escalas atitudinais utilizadas em estudos de consumidor: tradução e validação para a língua portuguesa. *Aliment e Nutr Araraquara*. (2006) 17:51–64.

WASSERMAN, L. *All of Statistics: A Concise Course in Statistical Inference*. New York: Springer, 2004.

WEISBERG, S. *Applied Linear Regression*. 3rd ed. Hoboken, NJ: John Wiley & Sons, 2005.